

Notes manuscrites sur le  
cours du mardi 18 / sept. / 2020  
(slides 18 à 23)

Fim de la partie du cours sur  
les Vecteurs Gaussiens

## I.4. Vecteurs gaussiens quelconques

---

**Définition d'un vecteur gaussien (seconde approche).**

Un vecteur aléatoire  $X = (X_1, \dots, X_d)^T \in \mathbb{R}^d$  est dit *gaussien (ou multi-gaussien) non dégénéré* (ou de dimension réelle  $d$ ) s'il existe  $\mu = (\mu_1, \dots, \mu_d) \in \mathbb{R}^d$ , une matrice  $A$  de taille  $d \times d$  **inversible** et  $\varepsilon \sim N(0, I_d)$  tels que

$$X = \mu + A\varepsilon$$

Dit autrement,  $X$  est l'image par une **transformation affine** d'un bruit blanc gaussien centré-réduit.

**Moyenne et matrice de covariance :**

$$E(X) = \mu$$

$$\text{Cov}(X) = AA^T$$

## Explications (rappels)

→ définition alternative en liaison avec

$$X = \mu + \sigma \varepsilon \quad \text{où} \quad \varepsilon = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

dans le cas  $d = 1$

$$\rightarrow X = \mu + A\varepsilon \Leftrightarrow \begin{pmatrix} X_1 \\ \vdots \\ X_d \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_d \end{pmatrix} + \underbrace{\begin{pmatrix} A & \\ & d \times d \end{pmatrix}}_{A \in \mathbb{R}^{d \times d}} \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_d \end{pmatrix}$$

$$\Rightarrow E(X) = \mu + AE(\varepsilon) = \mu$$

$$\text{Cov}(X) = E[(X - \mu)(X - \mu)^T] = E[A\varepsilon\varepsilon^T A^T]$$

$$= A \underbrace{E(\varepsilon\varepsilon^T)}_{\text{Id}} A^T = AA^T$$

## I.4. Vecteurs gaussiens quelconques

### Densité et décomposition de Mahalanobis\*.

Soit  $X$  un vecteur de la forme  $X = \mu + A\varepsilon \in \mathbb{R}^d$  avec  $A$  inversible et  $\varepsilon \sim N(0, I_d)$ . On a  $\Gamma = \text{Cov}(X) = AA^T$  inversible et  $X$  admet la densité

$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)}} \frac{1}{\sqrt{2\pi}^d} \exp\left(-\frac{1}{2} \langle x - \mu, \Gamma^{-1}(x - \mu) \rangle\right)$$

En bref,  $X \sim N(\mu, \Gamma)$  et  **$X$  gaussien au sens de la première définition.**

On a encore la décomposition  $X = \mu + U\Sigma Z$  avec  $Z \sim N(0, I_d)$  et où les matrices  $\Sigma$  et  $U$  sont obtenues par diagonalisation en base orthonormée de la matrice de covariance :  $\Gamma = U\Sigma^2 U^T$  avec  $U^T U = I_d$ .

(\* Prasanta Chandra Mahalanobis, 1893-1972)

Explications  $X = \mu + A\epsilon$  où  $A$  inversible,  $\epsilon \sim N(0, \mathbb{I}_d)$

$\Gamma = Cov(X) = AA^T$  est symétrique définie positive,

donc  $\Gamma$  diagonalise en base orthonormée :

$$\Gamma = U \Lambda U^T \text{ où } \left\{ \begin{array}{l} U^T U = \mathbb{I}_d \\ U \text{ matrice des V. p. en colonne} \end{array} \right.$$

On écrit :  $\Lambda = \Sigma^2$  où  $\Sigma = \begin{pmatrix} \sqrt{\lambda_1} & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sqrt{\lambda_d} \end{pmatrix}$

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \dots & \lambda_d \end{pmatrix} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d > 0$$

(spectre)

Alors

$$A = U \Sigma V^T \text{ où } V^T V = \mathbb{I}_d$$

En effet, posons  $V = A^T U \Sigma^{-1}$ .

Alors  $V^T = \Sigma^{-1} U^T A \Leftrightarrow A = U \Sigma V^T$

Puis,  $V^T V = \Sigma^{-1} U^T \underbrace{A A^T}_{\Gamma = U \Lambda U^T} U \Sigma^{-1} = \Sigma^{-1} \cancel{U^T} \cancel{U \Sigma^2 U^T} \cancel{U \Sigma^{-1}} = \mathbb{I}_d$

$$\text{Ainsi, } X = \mu + A\epsilon = \mu + U \underbrace{\Sigma}_{=Z} (V^T \epsilon)$$

Or  $Z \sim N(0, I_d)$  car  $\begin{cases} V^T = V^{-1} \text{ isométrie} \\ \epsilon \sim N(0, I_d) \end{cases}$


RQVE:  $\epsilon = \sum_{k=1}^d z_k v_k$  donc  $(z_1, \dots, z_d)$  sont les coordonnées euclidiennes de  $\epsilon$  dans la base orthonormée  $(v_1, \dots, v_k)$ , donc  $z_1, \dots, z_d$  i.i.d.  $N(0, 1)$ .

D'où la décomposition dite de Mahalanobis:

$$X^{(\omega)} = \mu + \sum_{k=1}^d \underbrace{\sqrt{\lambda_k} z_k(\omega)}_{\text{r.s.a. indépendantes}} u_k$$

resp  $\frac{t}{\lambda_k}$

le petit dessin en dim d=2 pour illustrer :



$$X - \mu = \underbrace{\sqrt{\lambda_1} Z_1}_{N(0, \lambda_1)} U_1 + \underbrace{\sqrt{\lambda_2} Z_2}_{N(0, \lambda_2)} U_2$$

independantes !

Ainsi, dans le repère orthonormé  $(\mu; U_1, \dots, U_d)$ , la densité du V.a.  $X$  s'écrit :

$$z \longrightarrow \frac{1}{\sqrt{\lambda_1} \cdots \sqrt{\lambda_d}} \frac{1}{\sqrt{2\pi}^d} e^{-\frac{1}{2} \sum_{i=1}^d \frac{z_i^2}{\lambda_i}}$$

(produit des densités marginales par indépendance)

Sous forme matricielle, cette densité s'écrit :

$$z \rightarrow \frac{1}{\sqrt{\det(\Gamma)} \sqrt{2\pi}^d} e^{-\frac{1}{2} z^T \Lambda^{-1} z}$$

En revenant au repère initial de  $\mathbb{R}^2$  :  $(0; e_1, e_2)$ ,

on obtient vu que  $z = U^T(x - \mu)$  :

$$f_X(x) = \frac{1}{\sqrt{\det(\Gamma)} \sqrt{2\pi}^d} e^{-\frac{1}{2} (x - \mu)^T \underbrace{U \Lambda^{-1} U^T}_{\Gamma^{-1}} (x - \mu)}$$

car :  $\Gamma = U \Lambda U^T$

donc  $X = \mu + A \varepsilon$  a bien la densité de probabilité attendue en liaison avec la définition usuelle de la loi  $N(\mu, \Gamma)$  à partir de sa densité !

Consequences:  $X = \mu + A\epsilon \Rightarrow e^{-\frac{1}{2}(x-\mu)^T \Gamma^{-1}(x-\mu)}$  est bien une densité de probabilité (où  $\Gamma = AA^T$ ) entièrement caractérisée donc par  $\mu = \text{moyenne}$  et  $\Gamma = \text{Cov}(X)$  matrice des variances-covariances du vecteur  $(X_1, \dots, X_d)$

- (1)  $x \rightarrow \frac{1}{\sqrt{\det(\Gamma)}} \sqrt{2\pi}^d$  est elles-mêmes gaussiennes car (par exemple)
- $X_1 = \mu_1 + A_{1,1}\epsilon_1 + \dots + A_{1,d}\epsilon_d$  est gaussienne par stabilité de la loi normale! (cf.  $\epsilon_1, \dots, \epsilon_d$  indépendantes)
- donc  $X_i \sim N(\mu_i, \sigma_i^2)$  où  $\sigma_i^2 = \Gamma_{ii}$
- (3)  $\begin{cases} B \text{ inversible} \\ b \in \mathbb{R}^d \end{cases} \Rightarrow Y = b + BX = b + B\mu + BAE$  est encore un V.G. de loi  $N(b + B\mu; BAA^T B^T)$

## I.4. Vecteurs gaussiens quelconques

---

**COROLLAIRE.** ☺

Si  $X \in \mathbb{R}^d$  est un vecteur gaussien non dégénéré, alors

$$\begin{aligned} X_1, \dots, X_d \text{ indépendantes} &\Leftrightarrow \text{Cov}(X_i, X_j) = 0 \text{ pour } i \neq j \\ &\Leftrightarrow \Gamma \text{ matrice diagonale} \end{aligned}$$

**SIMULATION DE  $\mathbf{X} \sim N(\mu, \Gamma)$ .**

- Faire la décomposition de Cholesky de  $\Gamma$ :  $\Gamma = SS^T$  avec  $S$  triangulaire inférieure (et diagonale positive)
- Simuler  $\varepsilon \sim N(0, I_d)$
- Calculer  $\mathbf{X} = \mu + S\varepsilon$

Sur le corollaire:  $X_1, \dots, X_d$  indépendantes  $\Rightarrow \Gamma$  diagonale  
est toujours vrai !

C'est la réciproque dans le cas  $X = (X_1, \dots, X_d)$  V.G. qui est intéressante :

$| X$  V.G avec  $\text{Cov}(X_i, X_j) = 0$  si  $i \neq j$   
 $\Rightarrow X_1, \dots, X_d$  v.a. indépendantes !

En effet, il suffit de remarquer que  
 $f_X(x) = \prod_{i=1}^d f_{X_i}(x_i)$  dans le cas  $\Gamma$  diagonale

Retenir donc que dans le cas d'1 Vecteur Gaußien  $X$ :  
non corrélation linéaire entre les composantes 2 à 2  
 $\Rightarrow$  indépendance !

## Sur la simulation d'un VG en pratique :

décomposition de Cholesky de  $\Gamma = \text{décomposition LU dans le cas symétrique} : U = L^T$  avec  $L$  triangulaire inférieure  
 On note souvent  $S = L$ , d'où

$$\Gamma = SS^T$$

En prenant  $\varepsilon \sim N(0, I_d)$ , on a bien

$$X = \mu + \overset{A}{\overbrace{S\varepsilon}} \text{ de loi } N(\mu, \Gamma)$$

puisque:  $E(X) = \mu$  et  $\text{Cov}(X) = SS^T = \Gamma$

$$\text{Exemple (d=2)} : X \sim N(\mu, \Gamma) ; \quad \Gamma = \begin{pmatrix} \sigma_1^2 & \rho \sigma_1 \sigma_2 \\ \rho \sigma_1 \sigma_2 & \sigma_2^2 \end{pmatrix}$$

$$\text{On écrit : } \begin{cases} X_1 = \mu_1 + \sigma_1 \gamma_1 \\ X_2 = \mu_2 + \sigma_2 \gamma_2 \end{cases} \\ \Rightarrow Y \sim N(0; \begin{pmatrix} 1 & e \\ e & 1 \end{pmatrix})$$

Décomposition de Cholesky de  $\Gamma_Y = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$ :  $\begin{pmatrix} \Delta_{11} & \Delta_{21} \\ \Delta_{21} & \Delta_{22} \end{pmatrix}$

on écrit  $\begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} = SS^T = \begin{pmatrix} \Delta_{11} & 0 \\ \Delta_{21} & \Delta_{22} \end{pmatrix} \begin{pmatrix} \Delta_{11} & 0 \\ \Delta_{21} & \Delta_{22} \end{pmatrix}$

puis on identifie successivement  $\Delta_{11}$ ,  $\Delta_{21}$  et  $\Delta_{22}$ :

$$1 = \Delta_{11}^2 \text{ et on prend } \Delta_{11} = \sqrt{1} = 1$$

$$\rho = \frac{\Delta_{21}}{\Delta_{11}} \quad \text{d'où} \quad \Delta_{21} = \rho$$

$$1 = \Delta_{21}^2 + \Delta_{22}^2 \quad \text{d'où} \quad \Delta_{22}^2 = 1 - \rho^2$$

$$\text{et on prend } \Delta_{22} = \sqrt{1 - \rho^2}$$

$$S = \begin{pmatrix} 1 & 0 \\ \rho & \sqrt{1 - \rho^2} \end{pmatrix}$$

De là :  $Y = S\epsilon \Leftrightarrow \begin{cases} Y_1 = \epsilon_1 \\ Y_2 = \rho \epsilon_1 + \sqrt{1 - \rho^2} \epsilon_2 \end{cases}$

et donc  $\begin{cases} X_1 = \mu_1 + \sigma_1 \epsilon_1 \\ X_2 = \mu_2 + \sigma_2 \rho \epsilon_1 + \sigma_2 \sqrt{1 - \rho^2} \epsilon_2 \end{cases}$

## Définition d'un vecteur gaussien (cas général).

Un vecteur aléatoire  $X = (X_1, \dots, X_p)^T \in \mathbb{R}^p$  est dit *gaussien (ou multi-gaussien)* s'il existe  $\mu = (\mu_1, \dots, \mu_p) \in \mathbb{R}^p$ , une matrice  $A$  de taille  $p \times q$  et  $\varepsilon \sim N(0, I_q)$  tels que

$$X = \mu + A\varepsilon \iff \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_p \end{pmatrix} + \begin{matrix} \left[ \begin{array}{c} \uparrow \\ A \end{array} \right] \\ \downarrow \end{matrix} \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_q \end{pmatrix}$$

$X$  image par une **transformation affine** de  $\mathbb{R}^q$  dans  $\mathbb{R}^p$  d'un bruit blanc gaussien centré-réduit de dimension  $q$ .

$$A : \mathbb{R}^q \rightarrow \mathbb{R}^p$$

**Moyenne et matrice de covariance du vecteur  $X$  :**

$$E(X) = \mu \in \mathbb{R}^p$$

$$\Gamma = \text{Cov}(X) = AA^T \text{ de taille } p \times p$$

$$AA^T : (p \times q) \times (q \times p) = p \times p$$

jeu de données avec  
p variables  
et n individus

situation  
courante  
en pratique!  
p peut être  
grand

Deux cas sont à envisager :

- $\Gamma = \text{Cov}(X) = AA^T$  est **inversible**, alors  $X$  est de dimension réelle  $d = p$  et admet la densité

$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)}} \frac{1}{\sqrt{2\pi}^p} \exp\left(-\frac{1}{2} \langle x - \mu, \Gamma^{-1}(x - \mu) \rangle\right)$$

RQVE: nécessairement,  $q \geq p$


- $\Gamma$  est non inversible,  $X$  est dit « dégénéré » et « vit » en réalité dans un sous-espace affine de dimension  $d < p$  (et  $d \leq q$ ). De manière plus précise, on a

$$X = \mu + \sqrt{\lambda_1} Z_1 U_1 + \dots + \sqrt{\lambda_d} Z_d U_d ; Z \sim N(0, I_d)$$

} cf. décomposition de Mahalanobis adaptée à cette situation

en écrivant que  $\Gamma = U \Lambda U^T$  avec  $U^T U = I_p$  et  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d > 0$  les valeurs propres non nulles de  $\Gamma$ .

Dans les deux cas, on dira que  $X$  est de loi  $N(\mu, \Gamma)$ .



**Exemple (cf. TP1) :** soit  $X$  une variable aléatoire à 3 modalités 0, 1 ou 2.

Notons  $Z_0 = \frac{1}{\sqrt{p_0}} (1_{X=0} - p_0)$ ,  $Z_1 = \frac{1}{\sqrt{p_1}} (1_{X=1} - p_1)$ ,  $Z_2 = \frac{1}{\sqrt{p_2}} (1_{X=2} - p_2)$

puis  ~~$\vec{Y}$~~  le vecteur dans  $\mathbb{R}^3$  de composantes  $Z_0$ ,  $Z_1$  et  $Z_2$ .

Par construction,  $\mu = E(Z) = 0$ .

Alors,  $\Gamma = \text{Cov}(Z)$  est une matrice **non inversible** et le théorème central limite affirme encore que

$$\frac{1}{\sqrt{n}} (Z^{(1)} + \dots + Z^{(n)}) \xrightarrow{n} N(\mathbf{0}, \Gamma)$$

si les  $Z^{(k)}$  ( $k \geq 1$ ) sont des vecteurs aléatoires indépendants de même loi que  $Z \in \mathbb{R}^3$ .

**Exercice :** analyser la loi en question et en déduire le test classique d'adéquation à une loi discrète ayant 3 modalités. Cas général.

Détaillons l'exemple qui nous a servi de "fil rouge" dans ce cours :

$$Z = \begin{pmatrix} Z_0 \\ Z_1 \\ Z_2 \end{pmatrix} \in \mathbb{R}^{d=3} \text{ avec } \begin{cases} Z_k = \frac{1}{\sqrt{p_k}} (\mathbb{1}_{X=k} - p_k) \\ X \in \{0, 1, 2\} \text{ variable ternaire} \end{cases}$$

Un calcul simple (déjà vu) donne :

$$\mu = EZ = 0 \quad \text{et} \quad \Gamma = \text{Cov}(Z) = \begin{pmatrix} 1-p_0 & -\sqrt{p_0 p_1} & -\sqrt{p_0 p_2} \\ -\sqrt{p_0 p_1} & 1-p_1 & -\sqrt{p_1 p_2} \\ -\sqrt{p_0 p_2} & -\sqrt{p_1 p_2} & 1-p_2 \end{pmatrix}$$

$\Gamma$  est dégénérée (non inversible) car

$$\Gamma \begin{pmatrix} \sqrt{p_0} \\ \sqrt{p_1} \\ \sqrt{p_2} \end{pmatrix} = 0 \Rightarrow \ker \Gamma \text{ de dim } \geq 1.$$

TCL multidimensionnel  $\Rightarrow \frac{1}{\sqrt{n}} \left\{ Z^{(1)} + \dots + Z^{(n)} \right\} \xrightarrow[n \text{ grand}]{\sim} N(0, \Gamma)$   
qui donc  $\Gamma$  est non inversible ! (pas de densité !)

Solution exo 11 : analyse de la loi  $N(0; \Gamma)$  où

$$\Gamma = \begin{pmatrix} 1-p_0 & -\sqrt{p_0 p_1} & -\sqrt{p_0 p_2} \\ -\sqrt{p_0 p_1} & 1-p_1 & -\sqrt{p_1 p_2} \\ -\sqrt{p_0 p_2} & -\sqrt{p_1 p_2} & 1-p_2 \end{pmatrix}$$

On voit qu'en réalité  $\Gamma = P^2 = P$  où  $P$  est un projecteur orthogonal.

Calculons par exemple  $[P^2]_{11}$  si  $P = \Gamma$  :

$$[P^2]_{11} = (1-p_0)^2 + p_0 p_1 + p_0 p_2 = (1-p_0) + p_0(1-p_0) = 1-p_0$$

donc  $[P^2]_{11} = P_{11} = \Gamma_{11}$ . De même :  $[P^2]_{ij} = P_{ij}$ .

Par ailleurs,  $P^T = \Gamma^T = P \Rightarrow P$  projecteur orthogonal.

On tout projecteur orthogonal se diagonalise sous la forme simple suivante :

$$P = U \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ \hline & & & 0 & \\ & & & & \ddots & 0 \end{pmatrix} U^T$$

si l'on choisit  $\left\{ \begin{array}{l} (U_1, \dots, U_n) \text{ b.o.n de } \text{Im } P \\ (U_{n+1}, \dots, U_d) \text{ b.o.n de } \text{ker } P \end{array} \right.$  (cf.  $\mathbb{R}^d = \text{Im } P \oplus \text{ker } P$ )

Dans notre cas,  $d=3$  et :

$$\text{Tr}(P) = \text{Tr}(\Gamma) = 1-p_0 + 1-p_1 + 1-p_2 = 3-1$$

soit  $\text{Tr}(P)=2$ .

Par ailleurs,  $\text{Tr}(P) = \sum_{k=1}^d \underbrace{\lambda_k}_{\text{r.p.} \in \{0,1\}} = \dim(\text{Im } P)$   $r = \dim(\text{Im } P) = 2$

Donc,  $P$  est le projecteur orthogonal correspondant à la projection orthogonale sur le plan vectoriel

$$\{x \in \mathbb{R}^3 \mid \langle x | u \rangle = 0\} \text{ où } u = \begin{pmatrix} \sqrt{p_0} \\ \sqrt{p_1} \\ \sqrt{p_2} \end{pmatrix} \in \ker P$$

parallèlement à  $\mathbb{R}.u$

De plus, la loi  $N(0; \Gamma)$  est la loi du V.a.

$$P \varepsilon \text{ où } \varepsilon \sim N(0, I_2)$$

puisque  $\text{Cov}(P\varepsilon) = P P^T = P^2 = \Gamma$

Le test classique d'adéquation à une loi discrète ayant k=3 modalités :

jeu de données :  $x_1 \ x_2 \ \dots \ x_n$  réalisations indépendantes  
 $\downarrow \downarrow$  de  $X \in \{0, 1, 2\}$   
 $x_1 \ x_2 \ x_n \mapsto i.i.d.$

$$1 \leq i \leq n : Z_k^{(i)} = \frac{1}{\sqrt{p_i}} (1_{X_i=k} - p_k) \Rightarrow Z^{(i)} = \begin{pmatrix} Z_0^{(i)} \\ Z_1^{(i)} \\ Z_2^{(i)} \end{pmatrix}$$

$$\text{Général : } \frac{1}{\sqrt{n}} (Z_0^{(1)} + \dots + Z_0^{(n)}) = \frac{1}{\sqrt{n}} \begin{pmatrix} \frac{N_0 - np_0}{\sqrt{p_0}} \\ \frac{N_1 - np_1}{\sqrt{p_1}} \\ \frac{N_2 - np_2}{\sqrt{p_2}} \end{pmatrix}$$

TCL  $\Rightarrow \frac{1}{\sqrt{n}} (Z^{(1)} + \dots + Z^{(n)}) \underset{n \text{ grande}}{\sim} N(0; I^2) = \text{loi de PE}$

DONC :  $\sum_{k=0}^2 \frac{(N_k - np_k)^2}{np_k} \underset{n \text{ gd}}{\sim} \|\text{PE}\|^2 \text{ de loi } \chi^2(d=2)$   
 car P projecteur de rang 2 !

Gn vient d'élucider le "fameux" test du  $\chi^2$ :

$$S := \sum_{k=0}^2 \frac{(N_k - n p_k)^2}{n p_k}$$

statistique de test

effectif observé sur  
l'échantillon de la modalité  
 $n^o k$  ( $k=0, 1, 2$ )

effectif théorique moyen

Mise en œuvre du test d'hypothèses:

$$H_0: p_0 = p_0^{(0)}; p_1 = p_1^{(0)}; p_2 = p_2^{(0)} \text{ contre } H_1 = \text{"non } H_0\text{"}$$

(par exemple avec  $p_0^{(0)} = 50\%$ ,  $p_1^{(0)} = 25\%$ ;  $p_2^{(0)} = 25\%$ )

Gn calcule la valeur  $S$  de  $S$  sous  $H_0$  et

si  $S \geqslant \text{seuil}$ , on rejette  $H_0$

Le calcul du seuil se fait en écrivant que

$$P(\text{"rejet de } H_0 \text{ à tort"}) = P_{H_0}(S \geq \text{seuil}) = \alpha$$

avec (par exemple) le risque  $\alpha = 5\%$  (risque de 1<sup>ère</sup> espèce) -

On  $S \underset{\text{n gd}}{\sim} \chi^2(d=2)$  sous  $H_0$  (si  $H_0$  "vraie")


donc le seuil vérifie (à peu près) l'équation :

$$P(\chi^2(d=2) \geq \text{seuil}) = \alpha$$



↓  
quantile d'  
ordre  $1-\alpha$  de la loi  
 $\chi^2(d=2)$

(loi exponentielle dans ce cas, vu en exercice)

 Cas général : idem sauf que  $S \underset{\text{n gd}}{\sim} \chi^2(k-1)$



**Une simulation d'un bruit blanc gaussien de taille 100 visualisé par un tracé séquentiel de ses composantes**



## Décomposition en valeurs singulières (DVS ou SVD):

A étant donnée de taille  $p \times q$ , il existe une matrice  $p \times q$   $\Sigma$  diagonale à termes diagonaux  $\geq 0$  telle que

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T \quad \text{avec} \quad \mathbf{V}^T\mathbf{V} = \mathbf{I}_q \text{ et } \mathbf{U}^T\mathbf{U} = \mathbf{I}_p$$

Ainsi,  $\Gamma = \mathbf{A}\mathbf{A}^T = \mathbf{U}\Lambda_p\mathbf{U}^T$       avec  $\Lambda_p = \Sigma\Sigma^T$  diagonale  $p \times p$

$$\mathbf{A}^T\mathbf{A} = \mathbf{V}\Lambda_q\mathbf{V}^T \quad \text{avec } \Lambda_q = \Sigma^T\Sigma \text{ diagonale } q \times q$$

Les termes diagonaux de  $\Sigma$  sont appelés *valeurs singulières* de la matrice A et sont le plus souvent rangées par ordre décroissant.

## II.1. Lois conditionnelles dans le cas discret

---

Soient  $Y$  v.a.r. et  $X$  v.a. **discrète**  $X \in \{x_1, x_2, \dots, x_p\}$ .

On appelle *loi conditionnelle de Y sachant X = x<sub>k</sub>* la loi de probabilité notée  $\mu_{Y|X=x_k}$  définie par

$$\mu_{Y|X=x_k}([a, b]) = P(Y \in [a, b] | X = x_k) = \frac{P(Y \in [a, b] \text{ et } X = x_k)}{P(X = x_k)}$$

L'ensemble des  $p$  lois de probabilité  $\mu_{Y|X=x_k}$  ( $1 \leq k \leq p$ ) est appelé *système des lois conditionnelles de Y sachant X*.

**Exemple 1.** Loi du pile ou face deux fois :  $Y$  = nombre total de pile,  $X$  résultat du premier lancer

## II.1. Lois conditionnelles dans le cas discret

**Cas où Y est également discrète :  $Y \in \{y_1, y_2, \dots, y_q\}$**

**les p lois conditionnelles de Y sachant X s'écrivent**

$$\mu_{Y|X=x_i} = \sum_{j=1}^q p_{j|i} \delta_{y_j} \text{ où } p_{j|i} = \frac{p_{ij}}{p_{i.}} = \frac{P(Y = y_j \text{ et } X = x_i)}{P(X = x_i)}$$

On a (!)

**X, Y indépendantes  $\Leftrightarrow \mu_{Y|X=x_i} = \mu_Y$  pour tout i**

$$\Leftrightarrow p_{j|i} = \frac{P(Y = y_j \text{ et } X = x_i)}{P(X = x_i)} = P(Y = y_j) = p_{.j}$$

## II.2. Lois conditionnelles dans le cas continu

$(X, Y) \in \mathbb{R}^2$  est un vecteur continu de densité  $(x, y) \rightarrow f_{(X, Y)}(x, y)$

La loi conditionnelle de  $Y$  sachant  $X = x$  est définie par la *densité conditionnelle* suivante

$$f_{Y|X=x}(y) = \frac{f_{(X, Y)}(x, y)}{f_X(x)}$$

pour tout  $x$  tel que  $f_X(x) = \int_{-\infty}^{+\infty} f_{(X, Y)}(x, y) dy \neq 0.$

**Exemple 2.**  $Y = X + \varepsilon$  où  $X \sim N(\mu_X, \sigma_X^2)$  et  $\varepsilon \sim N(0, \sigma^2)$  sont indépendantes

## II.2. Lois conditionnelles dans le cas continu

On a (!)

$$X, Y \text{ indépendantes} \Leftrightarrow \mu_{Y|X=x} = \mu_Y \Leftrightarrow f_{Y|X=x}(y) = \frac{f_{(X,Y)}(x,y)}{f_X(x)} = f_Y(y)$$

**FORMULE DE BAYES.**

$$f_{X|Y=y}(x) = \frac{f_{Y|X=x}(y) \times f_X(x)}{f_Y(y)}$$

sachant que  $f_Y(y) = \int_{-\infty}^{+\infty} f_{Y|X=x}(y) \times f_X(x) dx$  est simplement une constante de normalisation.

## II.3. Espérance conditionnelle

---

On a vu que l'information apportée par  $X = (X_1, \dots, X_p)$  modifie les probabilités que l'on a sur  $Y$  avec la notion de loi conditionnelle.

Il est tout autant naturel de se demander en quoi la connaissance des variables  $X_1, \dots, X_p$  réduit ou non l'incertitude que l'on a sur  $Y$  si l'on mesure cette incertitude en terme de dispersion usuelle, i.e. de variance.

😊😊😊 On introduit pour cela l'espace vectoriel  $L^2(P)$  des v.a. admettant une variance et muni du produit scalaire suivant :


$$\langle U, V \rangle = E(UV)$$

## II.3. Espérance conditionnelle

Définition de l'*espérance conditionnelle*  $E(Y | X)$  :

$E(Y | X)$  est la projection orthogonale de  $Y$  sur le sous-espace  $L^2(X)$  de  $L^2(P)$  défini par

$$L^2(X) = \{ Z = \varphi(X) \in L^2(P) \text{ avec } \varphi : I\!\!R^p \rightarrow I\!\!R \}.$$



Bien noter que  $E(Y | X)$  est une variable aléatoire!

## II.3. Espérance conditionnelle

### Formules de l'espérance totale et de la variance totale

$$Y = E(Y | X) + \varepsilon \quad \text{avec } E(\varepsilon) = 0 \text{ et :}$$

$$\text{Cov}(\varepsilon, \varphi(X)) = \langle \varepsilon, \varphi(X) \rangle = 0 \text{ si } \varphi(X) \in L^2(X)$$

En particulier :  $E(E(Y | X)) = E(Y)$  et  $\text{Var}(Y) = \text{Var}(E(Y | X)) + \text{Var}(\varepsilon)$

Dans cette décomposition,  **$\varepsilon$  est de variance minimale** : on ne peut pas réduire plus la variance résiduelle!

**Définition.** On définit le pourcentage de la variance de  $Y$  expliquée par  $X$  selon

$$\% \text{ de variance expliquée} = 100 \times \frac{\text{Var}(E(Y | X))}{\text{Var}(Y)} \%$$

$$\% \text{ de variance non expliquée ou résiduelle} = 100 \times \frac{\text{Var}(\varepsilon)}{\text{Var}(Y)} \%$$

## II.3. Espérance conditionnelle

**Espérance conditionnelle comme moyenne de la loi conditionnelle.** On a simplement

$$E(Y | X) = m(X)$$

où la fonction  $m$  vérifie

$$m(x) = \int_{-\infty}^{+\infty} y \times f_{Y|X=x}(y) dy = E(Y | X = x)$$

i.e.  $m(x)$  est la moyenne de la loi conditionnelle de  $Y$  sachant  $X = x$ .

De plus, on a **la formule de transfert conditionnel**

$$E(f(Y) | X) = \varphi(X) \text{ où } \varphi \text{ se calcule selon } \varphi(x) = \int f(y) d\mu_{Y|X=x}(y)$$

## II.3. Espérance conditionnelle

---

On termine par le cas gaussien.

**Si  $(X, Y) = (X_1, \dots, X_p, Y)$  est un vecteur gaussien, alors :**

- $E(Y | X) = E_L(Y | X)$  est une **fonction linéaire (affine)** des  $X_k$
- Le résidu  $\varepsilon$  est **indépendant** des  $X_k$  et de loi  $N(0, \text{Var}(\varepsilon))$  où

$$\text{Var}(\varepsilon) = \text{Var}(Y) - \text{Var}(E(Y | X))$$

- **La loi conditionnelle de  $Y$  sachant  $X = x$  est gaussienne de variance indépendante de  $x$  et égale à la variance du résidu  $\varepsilon$**