

Probabilités - 21h00 –

UP1 – Probabilités et Statistique Avancées Majeure Science des Données 2020-2021

Objectif. Apporter les outils et concepts indispensables à la bonne compréhension et utilisation des méthodes et techniques statistiques qui seront présentées dans les 3 autres UPs de la Majeure « Science des Données » :

UP2 : Apprentissage statistique et automatique

UP3 : Données temporelles et analyse spectrale

UP4 : Exploitation mathématique de simulateurs numériques

Contenu.

Ch. 1 (12h00) : Vecteurs Gaussiens (VGs)

Ch. 2 (9h00) : Lois Conditionnelles – Processus Aléatoires

Vecteurs Gaussiens (algèbre, géométrie, probabilités)

⇒ **Analyse de données, Régression, Plan d'Expériences, ...**

Lois conditionnelles ⇒ Processus Aléatoires

⇒ **Séries chronologiques, ...**

Cours: slides de cours + fiches TD et TP + supports sur Campus en complément

I.1. Loi gaussienne sur \mathbb{R}

X v.a.r. est dite de loi *normale* (ou *gaussienne*) de *moyenne* $\mu \in \mathbb{R}$ et de *variance* $\sigma^2 > 0$ (*écart-type* $\sigma > 0$) si sa *loi de probabilité* admet la *densité* suivante :

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Ainsi,

$$P(X \in [a, b]) = \int_a^b f_X(x) dx$$

On notera $X \sim N(\mu, \sigma^2)$.

Convention. $X = \mu$ est gaussienne dégénérée, i.e. $X \sim N(\mu, 0)$.

高斯退化

I.1. Loi gaussienne sur \mathbb{R}

Importance de la loi normale – Théorème Central Limite (TCL):

X_1, X_2, \dots indépendantes et identiquement distribuées (en abrégé i.i.d.) de moyenne μ et de variance σ^2

中心极限定理是概率论中最著名的结果之一。
它提出，大量的独立随机变量之和具有近似于正态的分布。

Considérons la suite des sommes partielles : $S_n = X_1 + \dots + X_n$ ($n \geq 1$).

Alors, pour tout $a < b$:

$$P\left(a \leq \frac{\sqrt{n}}{\sigma} \left(\frac{S_n}{n} - \mu\right) \leq b\right) = P\left(a \leq \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b\right) \rightarrow_n \int_a^b \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx$$

En pratique : $\frac{S_n}{n} \approx_{n \text{ grand}} N\left(\mu, \frac{\sigma^2}{n}\right) \Leftrightarrow S_n \approx_{n \text{ grand}} N(n\mu, n\sigma^2)$

Si les X_k sont $N(\mu, \sigma^2)$, alors $\frac{S_n}{n}$ est de loi $N(\mu, \frac{\sigma^2}{n})$ et S_n est de loi $N(n\mu, n\sigma^2)$.

I.1. Loi gaussienne sur \mathbb{R}

Exemple classique d'application : estimation d'une proportion p

X_1, X_2, \dots i.i.d. de loi de Bernoulli $B(p)$ avec $0 < p < 1$ (où $p = P(X = 1)$).

Alors, $S_n = X_1 + \dots + X_n$ de loi binomiale $B(n, p)$ et

- S_n à peu près de loi $N(np, np(1 - p))$ si n grand

- $\frac{S_n}{n} = p + \frac{\sqrt{p(1 - p)}}{\sqrt{n}} Z$ où Z est à peu près de loi $N(0, 1)$ si n grand

Estimation de p : $\frac{S_n}{n}$ estimateur naturel de p (estimateur de la moyenne)

$$IC_{95\%} = \left[\hat{p} - 1.96 \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} ; \hat{p} + 1.96 \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right]$$

I.2. Vecteurs aléatoires réels

Définition. $X = (X_1, \dots, X_d) \in \mathbb{R}^d$ où X_1, \dots, X_d sont des v.a. est appelé **vecteur aléatoire réel (V.a.r.) de dimension d (ou V.a.r. d-dimensionnel)**.

Exemple 1 – cas discret : X v.a. discrète à K modalités codées de $k = 0$ à $k = K - 1$

On note $p_k = P(X = k)$ pour $0 \leq k \leq K - 1$ de sorte que

$$p_0 = P(X = 0) = 1 - p_1 - \dots - p_{K-1}$$

On cherche à estimer les probabilités p_k (proportions) à partir d'un échantillon de taille n de la loi de X . On considère donc X_1, \dots, X_n i.i.d. de même loi que X .

On pose pour $0 \leq k \leq K - 1$:

$$N_k = \mathbf{1}_{X_1=k} + \dots + \mathbf{1}_{X_n=k} \text{ le nombre d'occurrence de la modalité n}^\circ k$$

sachant que $N_0 = n - N_1 - \dots - N_{K-1}$

☞ $\mathbf{N} = (N_1, \dots, N_{K-1})$ V.a.r. de dimension $(K - 1)$ et discret

I.2. Vecteurs aléatoires réels

Loi de N : c'est la loi dite **multinomiale**

$$P(N = (n_1, \dots, n_{K-1})) = \frac{n!}{n_1! \times \dots \times n_{K-1}! (n - n_1 - \dots - n_{K-1})!} p_1^{n_1} \times \dots \times p_{K-1}^{n_{K-1}} \times (1 - p_1 - \dots - p_{K-1})^{n - n_1 - \dots - n_{K-1}}$$

- $K = 2$: loi binomiale
- $K = 3$: loi trinomiale

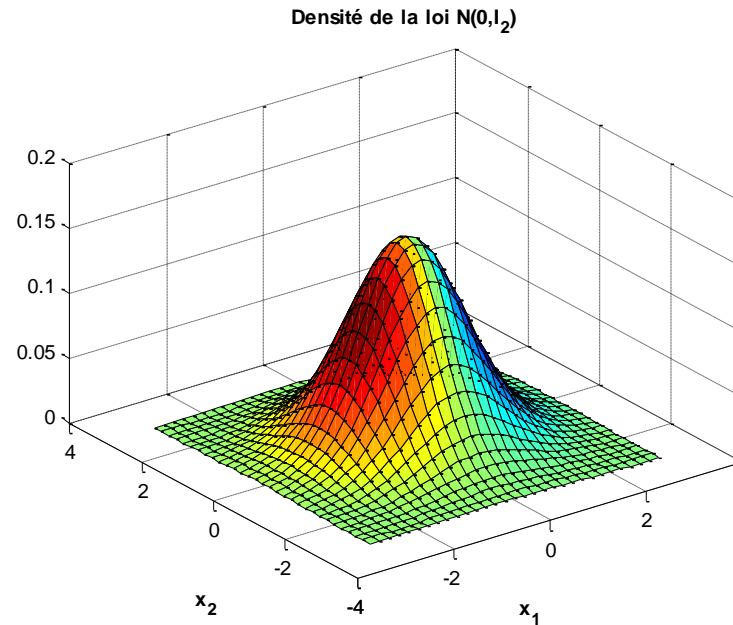
👉 elle sera étudiée en TP en liaison avec le TCL multi-dimensionnel

Exercice 1.

1. Déterminer les lois marginales du vecteur N
2. Que peut-on dire du V.a. $(N_0, N_1, \dots, N_{K-1})$?

I.2. Vecteurs aléatoires réels

Exemple 2 – cas continu : $X = (X_1, X_2)$ où X_1, X_2 sont i.i.d. de loi $N(0, 1)$



X admet la densité de probabilité suivante :

$$x = (x_1, x_2) \rightarrow \frac{1}{2\pi} \exp\left(-\frac{\|x\|^2}{2}\right)$$

👉 cloche de Gauss bi-dimensionnelle

I.2. Vecteurs aléatoires réels

Définition (densité d'un V.a. continu). $X = (X_1, \dots, X_d)^T \in \mathbb{R}^d$ V.a.r. est de densité $x = (x_1, \dots, x_d) \in \mathbb{R}^d \rightarrow f_X(x) \in \mathbb{R}$ si

$$P(X \in [a_1, b_1] \times \dots \times [a_d, b_d]) = \int_{[a, b]} f_X(x) dx$$

où $[a, b]$ est un hyper-rectangle quelconque $[a_1, b_1] \times \dots \times [a_d, b_d]$ de \mathbb{R}^d .

Lois marginales d'un V.a.r. : ce sont les lois des composantes X_1, \dots, X_d et admettent dans le cas continu des densités notées respectivement f_{X_1}, \dots, f_{X_d} .

Exercice 2. Exprimer les densités marginales f_{X_1}, \dots, f_{X_d} en fonction de la densité conjointe $x = (x_1, \dots, x_d) \rightarrow f_X(x)$ du V.a. continu X . Comparer avec le cas discret.

Cas indépendance : X_1, \dots, X_d indépendantes $\Leftrightarrow f_X(x) = f_{X_1}(x_1) \times \dots \times f_{X_d}(x_d)$

I.2. Vecteurs aléatoires réels

Définition – moyenne et matrice de (variance-)covariance d'un V.a.r. X d -dimensionnel :

- $\mu = (EX_1, \dots, EX_d)^T \in \mathbb{R}^d$ appelée **moyenne de X** : $\mu = E(X)$
- $\Gamma = E[(X - \mu)(X - \mu)^T] = (E[(X_i - \mu)(X_j - \mu)])_{i,j}$ matrice de taille $d \times d$ appelée **covariance de X** : $\Gamma = \text{Cov}(X)$

Propriété. La matrice Γ de terme général $\Gamma_{ij} = \text{Cov}(X_i, X_j)$ est une matrice symétrique positive. Sa diagonale est formée des variances individuelles des variables : $\Gamma_{ii} = \text{Cov}(X_i, X_i) = \text{Var}(X_i)$.

Exercice 3. Calculer moyenne et covariance du vecteur (N_1, N_2) associé à une loi trinomiale. En déduire la corrélation entre N_1 et N_2 .

Exercice 4. Si A est une application linéaire de \mathbb{R}^d dans \mathbb{R}^d (identifiée à une matrice $d \times d$) et b un vecteur de \mathbb{R}^d , calculer la moyenne et covariance du vecteur aléatoire $Y = AX + b$.

I.2. Vecteurs aléatoires réels

Définition (première approche) : Un vecteur aléatoire réel $X = (X_1, \dots, X_d)^T \in \mathbb{R}^d$ est dit **gaussien** (ou *multi-gaussien*) de *dimension réelle* d si

- sa matrice de covariance Γ est **inversible** (ou *non dégénérée*)
- et s'il admet la densité dite (multi-)gaussienne ou normale suivante :


$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)} \sqrt{2\pi}^d} \exp\left(-\frac{1}{2} \langle x - \mu, \Gamma^{-1}(x - \mu) \rangle\right)$$

Dans ce cas, $EX = \mu$.

On note encore $N(\mu, \Gamma)$ la loi normale multivariée de moyenne μ et de covariance Γ .

Exercice 5. Expliciter la densité d'un vecteur gaussien de dimension 2 et représenter sa densité.

I.2. Vecteurs aléatoires réels



I.2. Vecteurs aléatoires réels

Théorème Central Limite multidimensionnel

Soit X_1, X_2, \dots une suite de vecteurs aléatoires **indépendants et identiquement distribués** dans \mathbb{R}^d de vecteur moyenne μ et de matrice de covariance Γ supposée inversible. Pour $n \geq 1$, on note encore $S_n = X_1 + \dots + X_n \in \mathbb{R}^d$.

Alors, pour tout hyper-rectangle $[a, b]$ de \mathbb{R}^d

$$P\left(\frac{S_n - n\mu}{\sqrt{n}} \in [a, b]\right) \rightarrow_n \int_{[a, b]} f(x) dx$$

où f est la densité de la loi gaussienne multivariée $N(0, \Gamma)$.

En pratique :

$$\frac{S_n}{n} \approx N\left(\mu, \frac{1}{n} \Gamma\right)$$

I.3. Bruit blanc gaussien

Définition. X est dit *gaussien* (ou *normal*) *centré-réduit* si **ses composantes X_1, \dots, X_d sont indépendantes et de loi $N(0, 1)$** . C'est un vecteur aléatoire continu de loi admettant la *densité de probabilité*

$$\mathbf{x} = (x_1, \dots, x_d)^T \rightarrow \frac{1}{\sqrt{2\pi}^d} \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right)$$

où $\|\mathbf{x}\| = \sqrt{x_1^2 + \dots + x_d^2}$ désigne la norme euclidienne usuelle de \mathbb{R}^d .

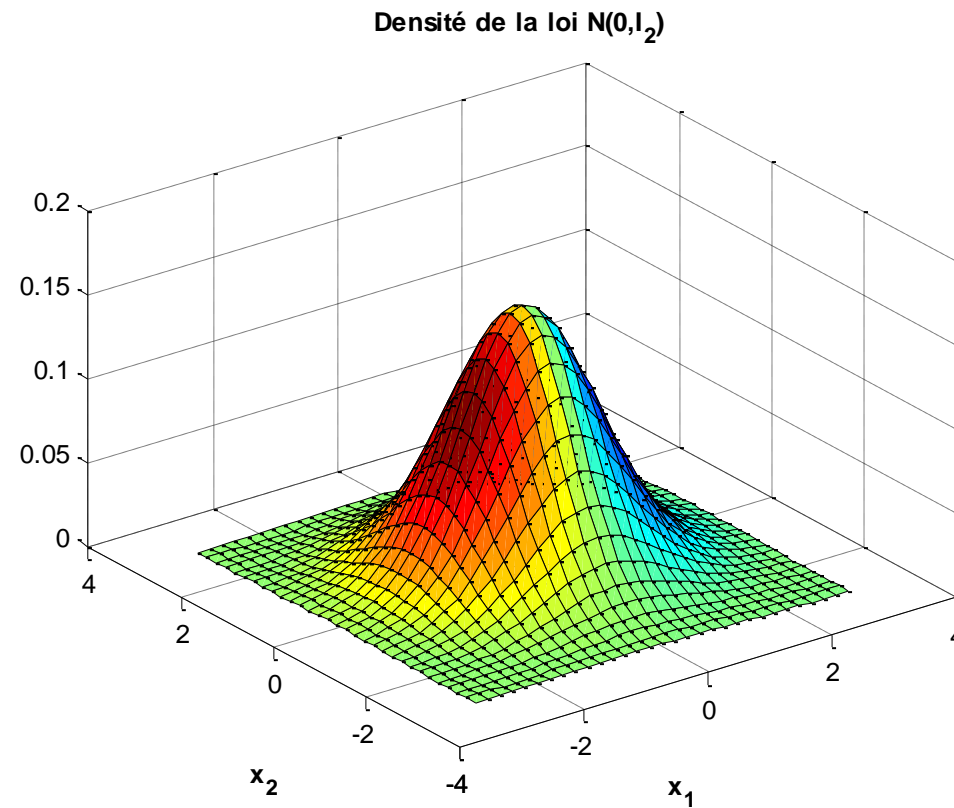
Interprétation. Les composantes du vecteur \mathbf{X} forment un bruit « blanc », ce qui renvoie aussi à la terminologie de **bruit blanc gaussien** (standard).

On a : $\mathbf{X} \sim N(\mathbf{0}, \mathbf{I}_d)$ où \mathbf{I}_d désigne la matrice *identité* de taille d , donc X est bien un vecteur gaussien au sens de la définition 1 (slide 11).


Dans toute la suite, ε désignera un vecteur aléatoire de loi $N(\mathbf{0}, \mathbf{I}_d)$.

I.3. Bruit blanc gaussien

Cas de la dimension $d = 2$:



I.3. Bruit blanc gaussien



$\varepsilon \sim N(0, I_d) \Rightarrow U\varepsilon \sim N(0, I_d)$ dès que $U^T U = I_d$
 U matrice orthogonale $\Leftrightarrow U$ isométrie $\Leftrightarrow U$ associée à une base orthonormée

I.3. Bruit blanc gaussien

Conséquence 1 - La loi normale est stable pour l'addition : $\forall n \geq 1$, on a :

X_1, \dots, X_n v.a.r. gaussiennes **indépendantes** $\Rightarrow X_1 + \dots + X_n$ v.a.r. gaussienne

Conséquence 2 (THÉORÈME DE COCHRAN*)

Soit P un projecteur orthogonal, i.e. $P^2 = P$ et $P^T = P$. Alors :

- $P\varepsilon$ et $(I - P)\varepsilon$ sont **indépendants**, gaussiens centrés-réduits de degrés de liberté (ou de dimensions respectives) p et $d - p$ où $p = \dim(\text{Im}P)$.
- Les v.a. $\|P\varepsilon\|^2$ et $\|(I - P)\varepsilon\|^2$ sont **indépendantes** de lois respectives

$$\|P\varepsilon\|^2 \sim \chi_p^2 \text{ et } \|(I - P)\varepsilon\|^2 \sim \chi_{d-p}^2$$

(*William Gemmel Cochran, 1909-1980)

I.4. Vecteurs gaussiens quelconques

Définition d'un vecteur gaussien (seconde approche).

Un vecteur aléatoire $X = (X_1, \dots, X_d)^T \in \mathbb{R}^d$ est dit *gaussien* (ou *multi-gaussien*) de **dimension réelle d** s'il existe $\mu = (\mu_1, \dots, \mu_d) \in \mathbb{R}^d$, une matrice A de taille $d \times d$ **inversible** et $\varepsilon \sim N(0, I_d)$ tels que

$$X = \mu + A\varepsilon$$

Dit autrement, X est l'image par une **transformation affine** d'un bruit blanc gaussien centré-réduit.

Moyenne et matrice de covariance :

$$E(X) = \mu$$

$$\text{Cov}(X) = AA^T$$

I.4. Vecteurs gaussiens quelconques

Densité et décomposition de Mahalanobis*.

Soit X un vecteur de la forme $X = \mu + A\varepsilon \in \mathbb{R}^d$ avec A inversible et $\varepsilon \sim N(0, I_d)$. On a $\Gamma = \text{Cov}(X) = AA^T$ *inversible* et X admet la densité

$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)} \sqrt{2\pi}^d} \exp\left(-\frac{1}{2} \langle x - \mu, \Gamma^{-1}(x - \mu) \rangle\right)$$

En bref, $X \sim N(\mu, \Gamma)$ et X gaussien au sens de la première définition.

On a encore la décomposition $X = \mu + U\Sigma\varepsilon$ avec $\varepsilon \sim N(0, I_d)$ et où les matrices Σ et U sont obtenues par diagonalisation en base orthonormée de la matrice de covariance : $\Gamma = U\Sigma^2U^T$ avec $U^T U = I_d$.

(* Prasanta Chandra Mahalanobis, 1893-1972)

I.4. Vecteurs gaussiens quelconques

COROLLAIRE. ☺

Si $X \in \mathbb{R}^d$ est un vecteur gaussien de dimension réelle d , alors

$$\begin{aligned} X_1, \dots, X_d \text{ indépendantes} &\Leftrightarrow \text{Cov}(X_i, X_j) = 0 \text{ pour } i \neq j \\ &\Leftrightarrow \Gamma \text{ matrice diagonale} \end{aligned}$$

SIMULATION DE $X \sim N(\mu, \Gamma)$.

- Faire la décomposition de Cholesky de Γ : $\Gamma = SS^T$ avec S triangulaire inférieure (et diagonale positive)
- Simuler $\varepsilon \sim N(0, I_d)$
- Calculer $X = \mu + S\varepsilon$

Définition d'un vecteur gaussien (cas général).

Un vecteur aléatoire $X = (X_1, \dots, X_p)^T \in \mathbb{R}^p$ est dit *gaussien* (ou *multi-gaussien*) s'il existe $\mu = (\mu_1, \dots, \mu_p) \in \mathbb{R}^p$, une matrice A de taille $p \times q$ et $\varepsilon \sim N(0, I_q)$ tels que

$$X = \mu + A\varepsilon$$

X image par une **transformation affine** de \mathbb{R}^q dans \mathbb{R}^p d'un bruit blanc gaussien centré-réduit de dimension q .

Moyenne et matrice de covariance du vecteur X :

$$E(X) = \mu \in \mathbb{R}^p$$

$$\Gamma = \text{Cov}(X) = AA^T \text{ de taille } p \times p$$

Deux cas sont à envisager :

- $\Gamma = \text{Cov}(X) = AA^T$ est **inversible**, alors X est de dimension réelle $d = p$ et admet la densité

$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)} \sqrt{2\pi}^p} \exp\left(-\frac{1}{2} \langle x - \mu, \Gamma^{-1}(x - \mu) \rangle\right)$$

- Γ est **non inversible**, X est dit « dégénéré » et « vit » en réalité dans un sous-espace affine de dimension $d < p$ (et $d \leq q$). De manière plus précise, on a

$$X = \mu + \sqrt{\lambda_1} \varepsilon_1 U_1 + \dots + \sqrt{\lambda_d} \varepsilon_d U_d ; \varepsilon \sim N(0, I_d)$$

en écrivant que $\Gamma = U \Lambda U^T$ avec $U^T U = I_p$ et $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d > 0$ les valeurs propres non nulles de Γ .

Dans les deux cas, on dira que X est de loi $N(\mu, \Gamma)$.

Exemple (cf. TP1) : soit X une variable aléatoire à 3 modalités 0, 1 ou 2.

Notons $Z_0 = \frac{1}{\sqrt{p_0}} (1_{X=0} - p_0)$, $Z_1 = \frac{1}{\sqrt{p_1}} (1_{X=1} - p_1)$, $Z_2 = \frac{1}{\sqrt{p_2}} (1_{X=2} - p_2)$

puis Z le vecteur dans \mathbb{R}^3 de composantes Z_0, Z_1 et Z_2 .

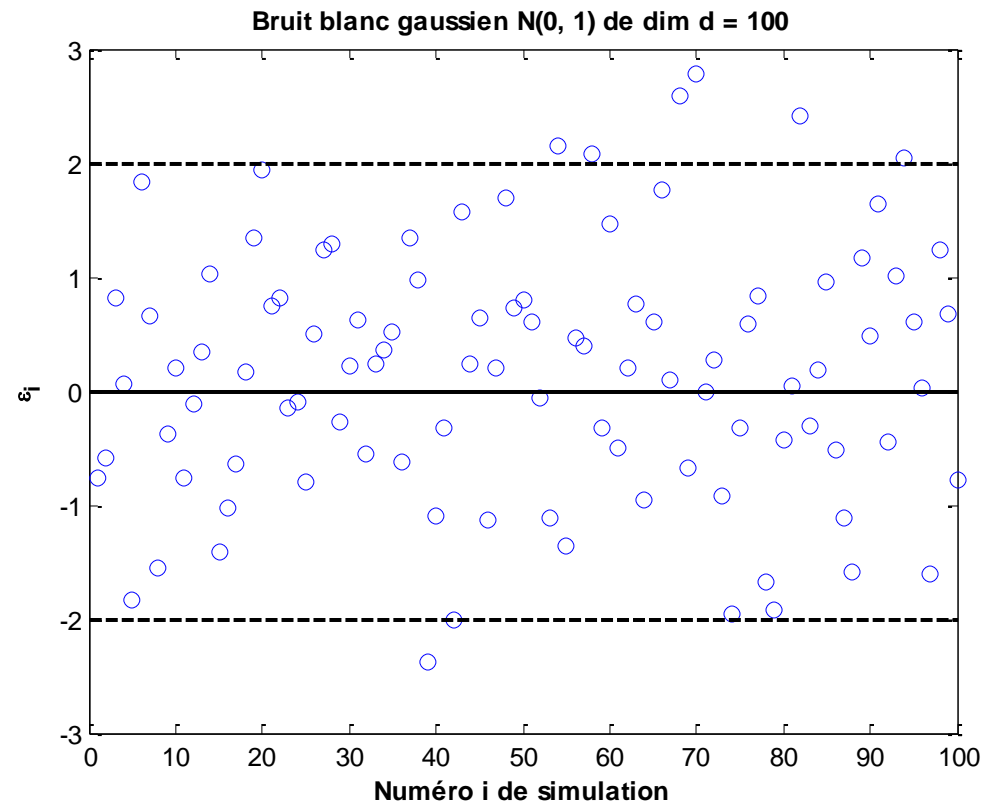
Par construction, $\mu = E(Z) = 0$.

Alors, $\Gamma = \text{Cov}(Z)$ est une matrice **non inversible** et le théorème central limite affirme que



$$\frac{1}{\sqrt{n}} (Z^{(1)} + \dots + Z^{(n)}) \rightarrow_n N(0, \Gamma)$$

si les $Z^{(k)}$ ($k \geq 1$) sont des vecteurs aléatoires indépendants de même loi que $Z \in \mathbb{R}^3$.

Exercice : analyser la loi en question et en déduire le test classique d'adéquation à une loi discrète ayant 3 modalités. Cas général.



**Une simulation d'un bruit blanc gaussien de taille 100
visualisé par un tracé séquentiel de ses composantes**



Décomposition en valeurs singulières (DVS ou SVD):

A étant donnée de taille $p \times q$, il existe une matrice $p \times q$ Σ diagonale à termes diagonaux ≥ 0 telle que

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T \quad \text{avec} \quad \mathbf{V}^T\mathbf{V} = \mathbf{I}_q \text{ et } \mathbf{U}^T\mathbf{U} = \mathbf{I}_p$$

Ainsi, $\mathbf{\Gamma} = \mathbf{A}\mathbf{A}^T = \mathbf{U}\mathbf{\Lambda}_p\mathbf{U}^T$ avec $\mathbf{\Lambda}_p = \Sigma\Sigma^T$ diagonale $p \times p$

$$\mathbf{A}^T\mathbf{A} = \mathbf{V}\mathbf{\Lambda}_q\mathbf{V}^T \quad \text{avec } \mathbf{\Lambda}_q = \Sigma^T\Sigma \text{ diagonale } q \times q$$

Les termes diagonaux de Σ sont appelés *valeurs singulières* de la matrice A et sont le plus souvent rangées par ordre décroissant.

II.1. Lois conditionnelles dans le cas discret

Soient Y v.a.r. et X v.a. **discrète** $X \in \{x_1, x_2, \dots, x_p\}$.

On appelle *loi conditionnelle de Y sachant $X = x_k$* la loi de probabilité notée $\mu_{Y|X=x_k}$ définie par

$$\mu_{Y|X=x_k}([a, b]) = P(Y \in [a, b] \mid X = x_k) = \frac{P(Y \in [a, b] \text{ et } X = x_k)}{P(X = x_k)}$$

L'ensemble des p lois de probabilité $\mu_{Y|X=x_k}$ ($1 \leq k \leq p$) est appelé *système des lois conditionnelles de Y sachant X* .

Exemple 1. Loi du pile ou face deux fois : Y = nombre total de pile, X résultat du premier lancer

II.1. Lois conditionnelles dans le cas discret

Cas où Y est également discrète : $Y \in \{y_1, y_2, \dots, y_q\}$

les p lois conditionnelles de Y sachant X s'écrivent

$$\mu_{Y|X=x_i} = \sum_{j=1}^q p_{j|i} \delta_{y_j} \text{ où } p_{j|i} = \frac{p_{ij}}{p_{i.}} = \frac{P(Y = y_j \text{ et } X = x_i)}{P(X = x_i)}$$

On a (!)

X, Y indépendantes $\Leftrightarrow \mu_{Y|X=x_i} = \mu_Y$ pour tout i

$$\Leftrightarrow p_{j|i} = \frac{P(Y = y_j \text{ et } X = x_i)}{P(X = x_i)} = P(Y = y_j) = p_{.j}$$

II.2. Lois conditionnelles dans le cas continu

$(X, Y) \in \mathbb{R}^2$ est un vecteur continu de densité $(x, y) \rightarrow f_{(X, Y)}(x, y)$

La loi conditionnelle de Y sachant $X = x$ est définie par la *densité conditionnelle* suivante

$$f_{Y | X=x}(y) = \frac{f_{(X, Y)}(x, y)}{f_X(x)}$$

pour tout x tel que $f_X(x) = \int_{-\infty}^{+\infty} f_{(X, Y)}(x, y) dy \neq 0$.

Exemple 2. $Y = X + \varepsilon$ où $X \sim N(\mu_X, \sigma_X^2)$ et $\varepsilon \sim N(0, \sigma^2)$ sont indépendantes

II.2. Lois conditionnelles dans le cas continu

On a (!)

$$\mathbf{X, Y \text{ indépendantes} \Leftrightarrow \mu_{Y|X=x} = \mu_Y \Leftrightarrow f_{Y|X=x}(y) = \frac{f_{(X,Y)}(x,y)}{f_X(x)} = f_Y(y)}$$

FORMULE DE BAYES.

$$f_{X|Y=y}(x) = \frac{f_{Y|X=x}(y) \times f_X(x)}{f_Y(y)}$$

sachant que $f_Y(y) = \int_{-\infty}^{+\infty} f_{Y|X=x}(y) \times f_X(x) dx$ est simplement une constante de normalisation.

II.3. Espérance conditionnelle

On a vu que l'information apportée par $X = (X_1, \dots, X_p)$ modifie les probabilités que l'on a sur Y avec la notion de loi conditionnelle.

Il est tout autant naturel de se demander en quoi la connaissance des variables X_1, \dots, X_p réduit ou non l'incertitude que l'on a sur Y si l'on mesure cette incertitude en terme de dispersion usuelle, i.e. de variance.

😊😊😊 On introduit pour cela l'espace vectoriel $L^2(P)$ des v.a. admettant une variance et muni du produit scalaire suivant :


$$\langle U, V \rangle = E(UV)$$

II.3. Espérance conditionnelle

Définition de l'espérance conditionnelle $E(Y | X)$:

$E(Y | X)$ est la projection orthogonale de Y sur le sous-espace $L^2(X)$ de $L^2(P)$ défini par

$$L^2(X) = \{ Z = \varphi(X) \in L^2(P) \text{ avec } \varphi : \mathbb{R}^p \rightarrow \mathbb{R} \}.$$



Bien noter que $E(Y | X)$ est une variable aléatoire!

II.3. Espérance conditionnelle

Formules de l'espérance totale et de la variance totale

$$Y = E(Y | X) + \varepsilon \quad \text{avec} \quad E(\varepsilon) = 0 \text{ et :}$$

$$\text{Cov}(\varepsilon, \varphi(X)) = \langle \varepsilon, \varphi(X) \rangle = 0 \text{ si } \varphi(X) \in L^2(X)$$

En particulier : $E(E(Y | X)) = E(Y)$ et $\text{Var}(Y) = \text{Var}(E(Y | X)) + \text{Var}(\varepsilon)$

Dans cette décomposition, ε est de variance minimale : on ne peut pas réduire plus la variance résiduelle!

Définition. On définit le pourcentage de la variance de Y expliquée par X selon

$$\% \text{ de variance expliquée} = 100 \times \frac{\text{Var}(E(Y | X))}{\text{Var}(Y)} \%$$

$$\% \text{ de variance non expliquée ou résiduelle} = 100 \times \frac{\text{Var}(\varepsilon)}{\text{Var}(Y)} \%$$

II.3. Espérance conditionnelle

Espérance conditionnelle comme moyenne de la loi conditionnelle. On a simplement

$$\mathbf{E(Y \mid X) = m(X)}$$

où la fonction m vérifie

$$\mathbf{m(x) = \int_{-\infty}^{+\infty} y \times f_{Y \mid X=x}(y) dy = E(Y \mid X = x)}$$

i.e. $m(x)$ est la moyenne de la loi conditionnelle de Y sachant $X = x$.

De plus, on a **la formule de transfert conditionnel**

$$\mathbf{E(f(Y) \mid X) = \varphi(X) \text{ où } \varphi \text{ se calcule selon } \varphi(x) = \int f(y) d\mu_{Y \mid X=x}(y)}$$

II.3. Espérance conditionnelle

On termine par le cas gaussien.

Si $(X, Y) = (X_1, \dots, X_p, Y)$ est un vecteur gaussien, alors :

- $E(Y | X) = E_L(Y | X)$ est une **fonction linéaire (affine)** des X_k
- Le résidu ε est **indépendant** des X_k et de loi $N(0, \text{Var}(\varepsilon))$ où

$$\text{Var}(\varepsilon) = \text{Var}(Y) - \text{Var}(E(Y | X))$$

- La loi conditionnelle de Y sachant $X = x$ est gaussienne de variance indépendante de x et égale à la variance du résidu ε