

# **Probabilités - 21h00 –**

**UP1 – Probabilités et Statistique Avancées  
Majeure Science des Données 2020-2021**

**Objectif.** Apporter les outils et concepts indispensables à la bonne compréhension et utilisation des méthodes et techniques statistiques qui seront présentées dans les 3 autres UPs de la Majeure « Science des Données » :

UP2 : Apprentissage statistique et automatique

UP3 : Données temporelles et analyse spectrale

UP4 : Exploitation mathématique de simulateurs numériques

**Contenu.**

**Ch. 1 (12h00) : Vecteurs Gaussiens (VGs)**

**Ch. 2 (9h00) : Lois Conditionnelles – Processus Aléatoires**

**Vecteurs Gaussiens (algèbre, géométrie, probabilités)**

⇒ **Analyse de données, Régression, Plan d'Expériences, ...**

**Lois conditionnelles ⇒ Processus Aléatoires**

⇒ **Séries chronologiques, ...**

**Cours: slides de cours + fiches TD et TP + supports sur Campus en complément**

## I.1. Loi gaussienne sur $\mathbb{R}$

---

$X$  v.a.r. est dite de loi *normale* (ou *gaussienne*) de *moyenne*  $\mu \in \mathbb{R}$  et de *variance*  $\sigma^2 > 0$  (*écart-type*  $\sigma > 0$ ) si sa *loi de probabilité* admet la *densité* suivante :

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Ainsi,

$$P(X \in [a, b]) = \int_a^b f_X(x) dx$$

**On notera  $X \sim N(\mu, \sigma^2)$ .**


**Convention.**  $X = \mu$  est gaussienne dégénérée, i.e.  $X \sim N(\mu, 0)$ .

A savoir sur la loi  $N(\mu, \sigma^2)$ :

$$X \sim N(\mu, \sigma^2) \iff X = \mu + \sigma Z \text{ avec } Z \sim N(0, 1)$$

$$\downarrow \quad \downarrow$$
$$EX \quad \text{Var}(X) = E[(X - EX)^2] = EX^2 - (EX)^2$$

$$\text{Var}(X) = 0 \iff X = EX = \mu \quad (\text{X dégénérée})$$



Intervalle de fluctuations à 95% :  $[\mu - 1.96\sigma, \mu + 1.96\sigma] \approx \mu \pm 2\sigma$   
De plus :  $\mu \pm \sigma \rightarrow \approx 68\%$  et  $\mu \pm 3\sigma \rightarrow \approx 99,7\%$

## I.1. Loi gaussienne sur $\mathbb{R}$

**Importance de la loi normale – Théorème Central Limite (TCL):**

$X_1, X_2, \dots$  indépendantes et identiquement distribuées (en abrégé i.i.d.) de moyenne  $\mu$  et de variance  $\sigma^2$

Considérons la suite des sommes partielles :  $S_n = X_1 + \dots + X_n$  ( $n \geq 1$ ).

Alors, pour tout  $a < b$  :

$$P(a \leq \frac{\sqrt{n}}{\sigma} \times (\frac{S_n}{n} - \mu) \leq b) = P(a \leq \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b) \xrightarrow{n} \int_a^b \frac{1}{\sqrt{2\pi}} \exp(-\frac{x^2}{2}) dx$$

En pratique :  $\frac{S_n}{n} \approx_{n \text{ grand}} N(\mu, \frac{\sigma^2}{n}) \Leftrightarrow S_n \approx_{n \text{ grand}} N(n\mu, n\sigma^2)$

Si les  $X_k$  sont  $N(\mu, \sigma^2)$ , alors  $\frac{S_n}{n}$  est de loi  $N(\mu, \frac{\sigma^2}{n})$  et  $S_n$  est de loi  $N(n\mu, n\sigma^2)$ .

## I.1. Loi gaussienne sur $\mathbb{R}$

---

### Exemple classique d'application : estimation d'une proportion p

$X_1, X_2, \dots$  i.i.d. de loi de Bernoulli  $B(p)$  avec  $0 < p < 1$  (où  $p = P(X = 1)$ ).

Alors,  $S_n = X_1 + \dots + X_n$  de loi binomiale  $B(n, p)$  et

- $S_n$  à peu près de loi  $N(np, np(1 - p))$  si n grand
- $\frac{S_n}{n} = p + \frac{\sqrt{p(1 - p)}}{\sqrt{n}} Z$  où Z est à peu près de loi  $N(0, 1)$  si n grand

Estimation de p :  $\frac{S_n}{n}$  estimateur naturel de p (estimateur de la moyenne)

$$IC_{95\%} = [\hat{p} - 1.96 \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} ; \hat{p} + 1.96 \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} ]$$

## Détails sur estimation de p (proba/proportion/taux/etc.)

$X \in \{0, 1\}$ ,  $p = P(X=1)$  (et donc  $1-p = P(X=0)$ )

$X_1, \dots, X_n$  i.i.d. de même loi que  $X$  ( $n$  épreuves de Bernoulli)

$\left\{ \begin{array}{l} S_n = X_1 + \dots + X_n = \text{"nombre de fois où 1 apparaît"} \end{array} \right.$

$\left\{ \begin{array}{l} \frac{S_n}{n} \text{ estimateur naturel de } p \end{array} \right.$

Alors  $\left\{ \begin{array}{l} S_n \text{ de loi } B(n, p) \text{ (loi binomiale)} \\ \frac{S_n}{n} \approx N(np, np(1-p)) \text{ si } n \text{ assez grand} \end{array} \right.$

$$\left\{ \begin{array}{l} \frac{S_n}{n} \approx N(p, \frac{p(1-p)}{n}) \end{array} \right.$$

Remarquer que :  $E\left(\frac{S_n}{n}\right) = p$  (estimateur sans biais)

et  $\text{Var}\left(\frac{S_n}{n}\right) = \frac{p(1-p)}{n} \xrightarrow{n} 0$  (estimateur convergent)

## Intérêt pratique

- ① Intervalle de confiance à 95% sur  $p$

$$IC_{95\%} = \hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

où  $\hat{p} := \bar{x} = \frac{x_1 + \dots + x_n}{n}$  (réalisation de  $\bar{X} = \frac{S_m}{m}$ )

désigne l'estimation ponctuelle de  $p$  (= nombre calculé à partir de l'échantillon  $x_1, x_2, \dots, x_m$ )

→  $IC_{95\%}$  estimation par intervalle  
ou fourchette d'estimation

- ② On peut tester l'hypothèse  $H_0: p = p_0$  contre  $H_1: p > p_0$   
(penser au Covid et  $p_0$  seuil critique de % de "positif"  
dans la population par exemple)

## I.2. Vecteurs aléatoires réels

---

**Définition.**  $X = (X_1, \dots, X_d) \in \mathbb{R}^d$  où  $X_1, \dots, X_d$  sont des v.a. est appelé **vecteur aléatoire réel (V.a.r.) de dimension d (ou V.a.r. d-dimensionnel)**.

**Exemple 1 – cas discret :**  $X$  v.a. discrète à  $K$  modalités codées de  $k = 0$  à  $k = K - 1$

On note  $p_k = P(X = k)$  pour  $0 \leq k \leq K - 1$  de sorte que

$$p_0 = P(X = 0) = 1 - p_1 - \dots - p_{K-1}$$

On cherche à estimer les probabilités  $p_k$  (proportions) à partir d'un échantillon de taille  $n$  de la loi de  $X$ . On considère donc  $X_1, \dots, X_n$  i.i.d. de même loi que  $X$ .

On pose pour  $0 \leq k \leq K - 1$  :

$$N_k = \mathbf{1}_{X_1=k} + \dots + \mathbf{1}_{X_n=k} \text{ le nombre d'occurrence de la modalité } n^{\circ}k$$


sachant que  $N_0 = n - N_1 - \dots - N_{K-1}$

☞  $\mathbf{N} = (N_1, \dots, N_{K-1})$  V.a.r. de dimension  $(K - 1)$  et discret

## Commentaire sur la terminologie X "vecteur" aléatoire :

Si l'on dispose de l'observation de plusieurs variables  $X_1, \dots, X_d$ , il est naturel de les considérer conjointement (pour apprendre les dépendances éventuelles)

$$\Rightarrow X = (X_1, X_2, \dots, X_d) \in \mathbb{R}^d$$



## I.2. Vecteurs aléatoires réels

---

**Loi de  $\mathbf{N}$**  : c'est la loi dite **multinomiale**

$$P(N = (n_1, \dots, n_{K-1})) = \frac{n!}{n_1! \times \dots \times n_{K-1}! (n - n_1 - \dots - n_{K-1})!} p_1^{n_1} \times \dots \times p_{K-1}^{n_{K-1}} \times (1 - p_1 - \dots - p_{K-1})^{n - n_1 - \dots - n_{K-1}}$$

- $K = 2$  : loi binomiale

- $K = 3$  : loi trinomiale

☞ loi étudiée au TP1 en liaison avec le TCL multi-dimensionnel

### Exercice 1.

1. Déterminer les lois marginales du vecteur  $\mathbf{N}$
2. Que peut-on dire du V.a.  $(N_0, N_1, \dots, N_{K-1})$  ?

Cas de la loi triminaire :  $X \in \{0, 1, 2\}$  à  $k=3$  modalités

Exemple: enquête de satisfaction ("marketing")

$$X = \begin{cases} \text{"Pas du tout satisfait"} & \longrightarrow 0 : p_0 \\ \text{"Satisfait"} & \longrightarrow 1 : p_1 \\ \text{"Très satisfait"} & \longrightarrow 2 : p_2 \end{cases} \quad (\text{sondage})$$

$\rightarrow p_k$  proportions dans la clientèle que l'on peut estimer/apprendre

$\rightarrow$  sondage aléatoire/randomisé de  $n$  clients où l'on suppose  $n \ll N$  : taille population globale

$$\Rightarrow \text{données : } \begin{array}{c|c|c|c|c|c} x_1 & x_2 & \cdots & & x_m \\ \hline 1 & 0 & 2 & 2 & 0 & \cdots & 1 \end{array}$$

$x_1, x_2, \dots, x_m$  réalisations de  $x_1, \dots, x_m$  i.i.d. de la loi de  $X$  ternaire avec  $P(X=k) = p_k$

Comme  $P_0 = 1 - P_1 - P_2$ , il suffit d'estimer  $P_1$ ,  $P_2$  et bien sûr :

$$\begin{cases} \hat{P}_1 = \frac{N_1}{n} & \text{"fréquence avec laquelle apparaît la modalité 1"} \\ \hat{P}_2 = \frac{N_2}{n} & \text{"----- 2"} \end{cases}$$

Formellement,  $N_1 = \sum_{x_i=1} + \dots + \sum_{x_n=1}$   
 = "n° de clients satisfaits"

$N_2 = \sum_{x_i=2} + \dots + \sum_{x_n=2}$   
 = "n° de clients très satisfaits"

et  $N_0 = n - N_1 - N_2 = \text{"n° de clients pas du tout satisfaits"}$

$$\Rightarrow \hat{P}_0 = \frac{N_0}{n} = 1 - \hat{P}_1 - \hat{P}_2$$

Loi de  $(N_1, N_2)$  = loi trinomiale :

$$P(N_1 = m_1 \text{ et } N_2 = m_2) = \frac{n!}{m_1! m_2! (n - m_1 - m_2)!}$$

où  $\begin{cases} 0 \leq m_1 \leq n \\ 0 \leq m_2 \leq n \\ m_1 + m_2 \leq n \end{cases}$

coefficient trimomial  
(cf.  $(a+b+c)^n = \dots$ )

$$\begin{aligned} \text{En effet : } P(N_1 = m_1 \text{ et } N_2 = m_2) &= \binom{n}{m_1} \times \binom{n}{n - m_1} \times " \\ &= \text{coeff. trimomial} \\ &\quad \text{après simplification !} \end{aligned}$$

$$P_1^{m_1} P_2^{m_2} (1 - P_1 - P_2)^{n - m_1 - m_2}$$

par  
indépendance

# Solution exercice 1 dans le cas $k = 3$ (adapter pour k quelconque)

1. loi de  $N_1 = \text{loi } \mathcal{B}(n, p_1)$


loi de  $N_2 = \text{loi } \mathcal{B}(n, p_2)$

puisque, par exemple,

$$N_1 = \mathbb{I}_{x_1=1} + \dots + \mathbb{I}_{x_n=1}$$


et  $\mathbb{I}_{x_i=1}$  de loi  $\mathcal{B}(p_1)$

2.  $N = (N_0, N_1, N_2)$  est un V.a. dégénérée de  $\mathbb{R}^3$   
puisque  $N \in \{(x, y, z) \in \mathbb{R}^3 \mid x+y+z=n\}$  (plan)



## I.2. Vecteurs aléatoires réels

**Exemple 2 – cas continu :**  $X = (X_1, X_2)$  où  $X_1, X_2$  sont i.i.d. de loi  $N(0, 1)$




$X$  admet la densité de probabilité suivante :

$$x = (x_1, x_2) \rightarrow \frac{1}{2\pi} \exp\left(-\frac{\|x\|^2}{2}\right)$$

☞ cloche de Gauss bi-dimensionnelle

## Exemple 2 : quelques explications

$$\begin{aligned} P((X_1, X_2) \in [a_1, b_1] \times [a_2, b_2]) &= P(X_1 \in [a_1, b_1] \text{ et } X_2 \in [a_2, b_2]) \\ &\stackrel{\text{rectangle } R \text{ de } \mathbb{R}^2}{=} P(X_1 \in [a_1, b_1]) \times P(X_2 \in [a_2, b_2]) \\ &\text{par définition} = \left( \int_{a_1}^{b_1} \frac{e^{-\frac{x_1^2}{2}}}{\sqrt{2\pi}} dx_1 \right) \times \left( \int_{a_2}^{b_2} \frac{e^{-\frac{x_2^2}{2}}}{\sqrt{2\pi}} dx_2 \right) \\ &\text{de } X_1, X_2 \text{ v.a. indépendantes} \\ &= \iint_R \frac{e^{-\frac{\|x\|^2}{2}}}{2\pi} dx_1 dx_2 \end{aligned}$$



donc  $X = (X_1, X_2)$  v.a. continue de densité:  $-\frac{\|x\|^2}{2}$

$$x = (x_1, x_2) \longrightarrow \frac{1}{2\pi} e^{-\frac{\|x\|^2}{2}} =: f_X(x)$$

On peut vérifier que:  $f_X(x) > 0$

et  $c = \iint_{\mathbb{R}^2} f_X(x) dx = 1$  puisque  
 $= dx_1 dx_2$

$$c = \int_0^{+\infty} \int_0^{2\pi} \frac{1}{2\pi} e^{-r^2/2} r dr d\theta = \int_0^{+\infty} r e^{-r^2/2} dr$$

$$\text{soit } c = \left[ -e^{-r^2/2} \right]_0^{+\infty} = 1 !$$

Ainsi, on a 2 exemples simples de :

①  $X$  V.a. discret avec  $(N_1, N_2)$

②  $X$  V.a. continu avec  $X = (X_1, X_2)$   
 où  $X_1, X_2$  iid  $N(0, 1)$ .

## I.2. Vecteurs aléatoires réels

---

**Définition (V.a. continu).**  $X = (X_1, \dots, X_d) \in \mathbb{R}^d$  V.a.r. est dit continu de densité  $x = (x_1, \dots, x_d) \in \mathbb{R}^d \rightarrow f_X(x) \geq 0$  si (par définition)

$$P(X \in [a_1, b_1] \times \dots \times [a_d, b_d]) = \int_{[a, b]} f_X(x) dx$$

où  $[[a, b]]$  désigne un hyper-rectangle quelconque  $[a_1, b_1] \times \dots \times [a_d, b_d]$  de  $\mathbb{R}^d$ .

**Lois marginales d'un V.a.r.** : ce sont les lois des composantes  $X_1, \dots, X_d$ . Dans le cas continu, elles admettent des densités notées respectivement  $f_{X_1}, \dots, f_{X_d}$ .

**Exercice 2.** Exprimer les densités marginales  $f_{X_1}, \dots, f_{X_d}$  en fonction de la densité conjointe  $x = (x_1, \dots, x_d) \rightarrow f_X(x)$  du V.a. continu  $X$ . Comparer avec le cas discret.

**Cas indépendance** :  $X_1, \dots, X_d$  indépendantes  $\Leftrightarrow f_X(x) = f_{X_1}(x_1) \times \dots \times f_{X_d}(x_d)$

Explications  $f_X(x) = f_X(x_1, \dots, x_d) \geq 0$  et


$$\int_{\mathbb{R}^d} f_X(x) dx = \int \cdots \int f_X(x_1, \dots, x_d) dx_1 \cdots dx_d = 1$$

pour que  $f_X$  soit une densité de probabilité d'1 V.a. continu.

Lois marginales = lois des composantes ou marges  $X_1, \dots, X_d$

Solution exercice 2 dans le cas  $d=2$  (généralisation facile):

$$P(X_1 \in [a_1, b_1]) = P((X_1, X_2) \in [a_1, b_1] \times \mathbb{R})$$



C'est analogue au cas discret puisque :

$$X \in \{x_1, \dots, x_k\} ; P_{k,l} = P((X,Y) = (x_k, y_l)) \\ Y \in \{y_1, \dots, y_L\} = P(X = x_k \text{ et } Y = y_l) \\ (\text{P}_{k,l} = \text{loi conjointe})$$

Alors

$$P(X = x_k) = \sum_{l=1}^L P(X = x_k \text{ et } Y = y_l)$$

Soit

$$\boxed{P(X = x_k) = \sum_{l=1}^L P_{k,l} \text{ pour } 1 \leq k \leq k}$$

A comparer avec  $f_X(x) = \int_{-\infty}^{+\infty} f_{(X,Y)}(x,y) dy$  en continu.

Même formule pour la loi marginale associée à  $Y$  !

Cas de l'indépendance: précisons l'  $\Leftrightarrow$ :

① si  $X_1, \dots, X_d$  sont des v.a. continues, de densités respectives  $f_{X_1}(x_1), \dots, f_{X_d}(x_d)$  alors

$X = (X_1, \dots, X_d)$  v.a. continu de densité

$$f_X(x) = f_{X_1}(x_1) \times \dots \times f_{X_d}(x_d)$$

En effet,  $P(X \in [a, b]) = \prod_{i=1}^d P(X_i \in [a_i, b_i])$  par indépendance

$$= \prod_{i=1}^d \int_{a_i}^{b_i} f_{X_i}(x_i) dx_i$$

$$= \int_{[a, b]} f_{X_1}(x_1) \dots f_{X_d}(x_d) dx_1 \dots dx_d$$

Donc  $X$  continu de densité  $f_X(x)$  !

② Si  $X$  V.a continue de densité

$$f_{X^n} = f_{X_1}(x_1) \cdots f_{X_d}(x_d)$$

alors  $X_1, \dots, X_d$  indépendantes !

$$\begin{aligned} \text{En effet, } \mathbb{P}(X \in [a, b]) &= \int_{[a, b]} f_{X^n} dx \\ &= \int^b_a \cdots \int^{b_d}_{a_d} f_{X_1}(x_1) \cdots f_{X_d}(x_d) dx_1 \cdots dx_d \\ &= \prod_{i=1}^d \int_{a_i}^{b_i} f_{X_i}(x_i) dx_i \\ &= \prod_{i=1}^d \mathbb{P}(X_i \in [a_i, b_i]) // \end{aligned}$$

## I.2. Vecteurs aléatoires réels

Définition – moyenne et matrice de (variance-)covariance d'un V.a.r.  $X$  d-dimensionnel :

- $\mu = (EX_1, \dots, EX_d) \in \mathbb{R}^d$  **moyenne de  $X$**  :  $\mu = EX$
- $\Gamma = E[(X - \mu)(X - \mu)^T] = (E[(X_i - \mu_i)(X_j - \mu_j)])_{i,j}$  matrice de taille  $d \times d$  appelée **covariance de  $X$**  :  $\Gamma = \text{Cov}(X)$

Attention à l'abus de notation :   $\text{Cor}(X) = \text{matrice de covariance}$

Propriété. La matrice  $\Gamma$  de terme général  $\Gamma_{ij} = \text{Cov}(X_i, X_j)$  est une matrice symétrique positive. Sa diagonale est formée des variances individuelles des variables :  $\Gamma_{ii} = \text{Cov}(X_i, X_i) = \text{Var}(X_i)$ .

**Exercice 3.** Calculer moyenne et covariance du vecteur  $(N_1, N_2)$  associé à une loi trinomiale. En déduire la corrélation entre  $N_1$  et  $N_2$ .

**Exercice 4.** Si  $A$  est une application linéaire de  $\mathbb{R}^d$  dans  $\mathbb{R}^d$  (identifiée à une matrice  $d \times d$ ) et  $b$  un vecteur de  $\mathbb{R}^d$ , calculer la moyenne et covariance du vecteur aléatoire  $Y = AX + b$ .

Explications sur moyenne et covariance d'un V.a.  $X = (X_1, \dots, X_d)$  :

on souhaite généraliser les notions de moyenne et variance  
de  $X$  v.a.  $\in \mathbb{R}$  ( $d=1$ )

D'où  $E X = (E X_1, \dots, E X_d) \Leftrightarrow \mu = (\mu_1, \dots, \mu_d)$

$\rightsquigarrow \mu$  vecteur des moyennes individuelles

Pour définir la covariance, on utilise le calcul matriciel  
avec la convention usuelle :

$$X = \begin{pmatrix} X_1 \\ \vdots \\ X_d \end{pmatrix} \text{ vecteur colonne ou matrice } d \times 1$$

De même donc  $\mu = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_d \end{pmatrix}$  et  $X - \mu = \begin{pmatrix} X_1 - \mu_1 \\ \vdots \\ X_d - \mu_d \end{pmatrix}$

Ainsi :  $(X - \mu)(X - \mu)^T = \begin{pmatrix} X_1 - \mu_1 \\ \vdots \\ X_d - \mu_d \end{pmatrix} \left( \begin{array}{c} (X_1 - \mu_1) \dots (X_d - \mu_d) \\ (X_i - \mu_i)(X_j - \mu_j) \end{array} \right)_{i,j}$  de taille  $d \times d$

$$\text{De là } \text{Cov}(X) = E \left[ (X - \mu)(X - \mu)^T \right] = \left( E \left[ [x_i - \mu_i][x_j - \mu_j]^T \right] \right)_{i,j}.$$

Sachant que l'on définit

$$E \left( \underset{\uparrow}{M} \right) = \left( EM_{ij} \right)_{i,j}.$$

matrice dont les

termes sont des v.a.r.

$$( \text{généralement } E \left[ \begin{pmatrix} X_1 \\ \vdots \\ X_d \end{pmatrix} \right] = \begin{pmatrix} EX_1 \\ \vdots \\ EX_d \end{pmatrix} )$$

On voit donc que

$$\text{Cov}(X) = \left( \text{Cov}(X_i, X_j) \right)_{1 \leq i, j \leq d}$$

où  $\text{Cov}(X_i, X_j)$  est la covariance entre les deux v.a.r.  $X_i$  et  $X_j$ .

Rappel : Si  $U, V$  sont deux v.a. réelles, alors

$$\text{Cov}(U, V) = E[(U - E(U))(V - E(V))] = E(UV) - E(U) \times E(V)$$

$$\text{Cov}(U, U) = \text{Var}(U) !$$

De plus,  $\rho_{U,V} = \frac{\text{Cov}(U, V)}{\sqrt{\text{Var}(U)} \sqrt{\text{Var}(V)}} = \frac{\text{Cov}(U, V)}{\sigma_U \sigma_V}$   $E[-1; +1]$

coefficient de corrélation linéaire

Bien remarquer que  $(U, V) \mapsto \text{Cov}(U, V) \in \mathbb{R}$

est une forme bilinéaire symétrique positive !  
(la variance est la forme quadratique associée)

Retenir que

$$\text{Cov}(X) = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & & \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & & \\ \vdots & & \ddots & \\ & & & \text{Var}(X_d) \end{pmatrix}$$

est la matrice des variances-covariances

des V. a.  $X = \begin{pmatrix} X_1 \\ \vdots \\ X_d \end{pmatrix}.$

C'est la généralisation de  $\sigma^2 = \text{Var}(X)$  du cas  $d=1$  au cas  $d \geq 2$ :  $\text{Cov}(X)$  intègre les corrélations linéaires entre les composantes 2 à 2 puisque:

$$\text{Cov}(X) = \begin{pmatrix} \sigma_1^2 & \rho_{1,2} \sigma_1 \sigma_2 \\ \rho_{1,2} \sigma_1 \sigma_2 & \sigma_2^2 \\ & \ddots \\ & & \sigma_d^2 \end{pmatrix}$$

en notant  $\left\{ \begin{array}{l} \sigma_i^2 = \text{Var}(X_i) \end{array} \right.$

$$\rho_{i,j} = \text{Cor}(X_i, X_j) = \frac{\text{Cov}(X_i, X_j)}{\sigma_i \sigma_j} \in [-1, +1]$$

Sur la propriété:  $\text{Cov}(X)$  matrice symétrique positive

Résulte de:  $0 \leq \text{Var}(a_1 X_1 + \dots + a_d X_d) = a^T \Gamma a$

en notant  $a = \begin{pmatrix} a_1 \\ \vdots \\ a_d \end{pmatrix}$

Solution exercice 3 :  $N = (N_1, N_2)$  où ( rappel )

$$\begin{cases} N_1 = \mathbb{1}_{X_1=1} + \dots + \mathbb{1}_{X_n=1} & \sim \mathcal{B}(n, p_1) \\ N_2 = \mathbb{1}_{X_1=2} + \dots + \mathbb{1}_{X_n=2} & \sim \mathcal{B}(n, p_2) \end{cases}$$

Dès lors  $\text{Var}(N_1) = n p_1 (1-p_1)$  et  $\text{Var}(N_2) = n p_2 (1-p_2)$

Puis,  $\text{Cov}(N_1, N_2) = E(N_1 N_2) - (E N_1) \times (E N_2)$

$$\begin{aligned} \text{Or a } E(N_1 N_2) &= \sum_{i,j} E[\mathbb{1}_{X_i=1} \mathbb{1}_{X_j=2}] \\ &= \sum_{i=1}^n E[\underbrace{\mathbb{1}_{X_i=1} \mathbb{1}_{X_i=2}}_{=0}] + \sum_{i \neq j} \end{aligned}$$

$$= \sum_{i \neq j} \underline{P(X_i=1)} \underline{P(X_j=2)} \quad (\text{par indépendance})$$

$$\begin{aligned} \text{De là, } \text{Cov}(N_1, N_2) &= \cancel{(n^2 - n)} p_1 p_2 - \cancel{(n p_1)} \cancel{(n p_2)} \\ &= -n p_1 p_2 \end{aligned}$$

et donc :

$$\text{Cov}(N) = \begin{pmatrix} n p_1(1-p_1) & -n p_1 p_2 \\ -n p_1 p_2 & n p_2(1-p_2) \end{pmatrix}$$

On en déduit

$$\rho_{N_1, N_2} = -\sqrt{\frac{p_1 p_2}{(1-p_1)(1-p_2)}}$$

Dans le cas  $p_0 = 0$ ,  $p_1 + p_2 = 1$

et  $\rho_{N_1, N_2} = -1$

Ce qui est logique puisque alors  $N_1 + N_2 = n$   
( $N_0 = 0$ ) .

Solution exercice 4 (connaître le résultat ou savoir refaire ce type de calcul)

$$Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_d \end{pmatrix} = \underbrace{AX + b}_{\text{matrice } d \times d \text{ déterministe}} \quad \text{où } X = \begin{pmatrix} X_1 \\ \vdots \\ X_d \end{pmatrix}; \quad b = \begin{pmatrix} b_1 \\ \vdots \\ b_d \end{pmatrix} \in \mathbb{R}^d$$

$Y$  = transformation linéaire (affine) des V.a.  $X$

On a  $\begin{cases} \mathbb{E} Y = A \mathbb{E} X + b \\ \text{Cov}(Y) = A \text{Cov}(X) A^T \end{cases}$

En effet, comme l'espérance est linéaire, on a

$$\begin{cases} \mathbb{E} Y_1 = a_{11} \mu_1 + \dots + a_{1d} \mu_d + b_1 \\ \vdots \\ \mathbb{E} Y_d = a_{d1} \mu_1 + \dots + a_{dd} \mu_d + b_d \end{cases} \quad \text{si } \mu = \mathbb{E} X$$

Soit donc  $\mu_y = A\mu_x + b$

On dit que l'opérateur  $E$  "traverse" la matrice  $A$

puisque  $E(AX+b) = AEX+b$  !

Puis,  $y - \mu_y = \cancel{AX+b} - (A\mu_x + b)$

soit  $y - \mu_y = A(x - \mu)$  partie aléatoire

Donc  $(y - \mu_y)(y - \mu_y)^T = A \underbrace{(x - \mu)(x - \mu)^T}_{\text{partie aléatoire}} A^T$

et, de même,  $\text{Cov}(y) = E[\downarrow] = A E[\leftarrow] A^T$

soit  $\text{Cov}(y) = A \text{Cov}(x) A^T //$

Petite illustration : cf. TPO (étude de la loi normale bidimensionnelle)

$$\begin{cases} X = aU + bV \\ Y = cU + dV \end{cases} \quad \text{avec } U, V \text{ i.i.d. } N(0, 1)$$

Alors  $\begin{pmatrix} X \\ Y \end{pmatrix} = \underbrace{\begin{pmatrix} a & b \\ c & d \end{pmatrix}}_A \begin{pmatrix} U \\ V \end{pmatrix}$  avec  $\text{Cov}\left(\begin{pmatrix} U \\ V \end{pmatrix}\right) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I_2$

$$\text{Cov}\left(\begin{pmatrix} X \\ Y \end{pmatrix}\right) = A I_2 A^T = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} a & c \\ b & d \\ a^2 + b^2 & ac + bd \\ ca + db & c^2 + d^2 \end{pmatrix}$$

$$\Rightarrow \text{Cov}\left(\begin{pmatrix} X \\ Y \end{pmatrix}\right) = \begin{pmatrix} a^2 + b^2 & ac + bd \\ ac + bd & c^2 + d^2 \end{pmatrix} //$$

Le calcul direct donne bien en effet  $\text{Var}(X) = a^2 + b^2$ ,  
 $\text{Var}(Y) = c^2 + d^2$  et  $\text{Cov}(X, Y) = ac + bd \dots$

## I.2. Vecteurs aléatoires réels

**Définition (première approche) :** Un vecteur aléatoire réel  $X = (X_1, \dots, X_d)^T \in \mathbb{R}^d$  est dit *gaussien* (*ou multi-gaussien*) non dégénéré si

- sa matrice de covariance  $\Gamma$  est *inversible* (ou *non dégénérée*)
- et s'il admet la densité dite (multi-)gaussienne ou normale suivante :

$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)}} \frac{1}{\sqrt{2\pi}^d} \exp\left(-\frac{1}{2} \underbrace{\langle x - \mu | \Gamma^{-1}(x - \mu) \rangle}_{Q(x) = (x - \mu)^T \Gamma^{-1} (x - \mu)}\right)$$

On vérifie que cette expression définit bien une densité associée à un vecteur aléatoire de moyenne  $\mu$  et de covariance  $\Gamma$ .

$$d=1: Q(x) = \frac{(x - \mu)^2}{\sigma^2}$$

On note encore  $N(\mu, \Gamma)$  la loi normale multivariée de moyenne  $\mu$  et de covariance  $\Gamma$ .

Comment retenir / retrouver cette expression analytique

Prenons  $X_1 \sim N(\mu_1, \sigma_1^2), \dots, X_d \sim N(\mu_d, \sigma_d^2)$  independantes

Alors

$$f_X(x) = \frac{1}{\prod_{i=1}^d \sigma_i \sqrt{2\pi}} e^{-\frac{1}{2} \frac{(x_i - \mu_i)^2}{\sigma_i^2}}$$
$$-\frac{1}{2} (x - \mu)^T \begin{pmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \dots & \frac{1}{\sigma_d^2} \end{pmatrix} (x - \mu)$$

$$f_X(x) = \frac{1}{(\sigma_1 \dots \sigma_d) \sqrt{2\pi}^d} e^{-\frac{1}{2} (x - \mu)^T \begin{pmatrix} \frac{1}{\sigma_1^2} & 0 & \dots & 0 \\ 0 & \ddots & & 0 \\ \vdots & & \ddots & 0 \\ 0 & 0 & \dots & \frac{1}{\sigma_d^2} \end{pmatrix} (x - \mu)}$$

Or  $\Gamma = \text{Cor}(X) = \begin{pmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \ddots & & 0 \\ \vdots & & \ddots & 0 \\ 0 & 0 & \dots & \sigma_d^2 \end{pmatrix}$

donc  $\boxed{f_X(x) = \frac{1}{\sqrt{\det(\Gamma)} \sqrt{2\pi}^d} e^{-\frac{1}{2} (x - \mu)^T \Gamma^{-1} (x - \mu)}}$

Ce calcul montre qu'un V.a.  $X = \begin{pmatrix} X_1 \\ \vdots \\ X_d \end{pmatrix}$  dont les


Composantes sont des N.a.r. gaussiennes indépendantes (et non dégénérées :  $\sigma_i > 0$ ) est bien un vecteur gaussien (VG)

Par ailleurs dans le cas  $d=1$  où  $X \sim N(\mu, \sigma^2)$ ,  
on a  $\text{Cor}(x) = \sigma^2$  (scalaire) et

$$f_X(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \frac{(x-\mu)}{\sigma^2} (x-\mu)}$$

## I.2. Vecteurs aléatoires réels

**Exercice 5.** Expliciter la densité d'un vecteur gaussien de dimension 2 et représenter sa densité.



Solution exercice 5       $X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$  vecteur gaussien non dégénéré

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \text{ et } \Gamma = \text{Cor}(X) = \begin{pmatrix} \sigma_1^2 & \rho \sigma_1 \sigma_2 \\ \rho \sigma_1 \sigma_2 & \sigma_2^2 \end{pmatrix}$$

où  $\sigma_1^2 = \text{Var}(X_1)$ ;  $\sigma_2^2 = \text{Var}(X_2)$ ;  $\rho = \text{Cor}(X_1, X_2)$

On a  $\det(\Gamma) = \sigma_1^2 \sigma_2^2 (1 - \rho^2) \geq 0$  car  $|\rho| \leq 1$

$\Gamma$  inversible  $\iff |\rho| < 1 \iff \rho \neq \pm 1$

On a :

$$\Gamma^{-1} = \frac{1}{\det(\Gamma)} \begin{pmatrix} \sigma_2^2 - \rho \sigma_1 \sigma_2 & -\rho \sigma_1 \sigma_2 \\ -\rho \sigma_1 \sigma_2 & \sigma_1^2 \end{pmatrix} \quad Q(x)$$

et donc

$$f_X(x) = \frac{1}{\sigma_1 \sigma_2 \sqrt{1 - \rho^2} \times 2\pi} e^{-\frac{1}{2} Q(x)}$$

$$\text{où } Q(x) = \frac{1}{\det(\Gamma)} \begin{pmatrix} x_1 - \mu_1 & x_2 - \mu_2 \end{pmatrix} \begin{pmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{pmatrix} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix}$$

En développant (forme quadratique en  $x_1, x_2$ ) :

$$Q(x) = \frac{1}{\det(\Gamma)} \left\{ \sigma_2^2 (x_1 - \mu_1)^2 + \sigma_1^2 (x_2 - \mu_2)^2 - 2\rho\sigma_1\sigma_2(x_1 - \mu_1)(x_2 - \mu_2) \right\}$$

et (rappel)

$$f_X(x) = \frac{1}{\sigma_1\sigma_2\sqrt{1-\rho^2} \times 2\pi} e^{-\frac{1}{2} Q(x)}$$

Tout cela est compliqué du fait de  $\Gamma^{-1}$  que l'on ne calcule jamais dès que  $d \geq 3$  (sauf cas simples ...).

Néanmoins, il est facile de se représenter cette densité par ses lignes / colonnes du niveau :

$$f_X(x) = \text{cste} \iff (x - \mu)^T \Gamma^{-1} (x - \mu) = \text{cste}$$

OR:  $\Gamma$  symétrique positive se diagonalise en base orthonormée

$$\Gamma = U \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \Leftrightarrow \Gamma = U \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} U^T$$

où  $U = \begin{pmatrix} U_1 & U_2 \end{pmatrix}$  = matrice des vecteurs propres (normés)  
vecteurs colonne

verified  $U^T U = I_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$


( $U^{-1} = U^T \Leftrightarrow U$  matrice orthogonale)

$$\text{De là, } \Gamma^{-1} = U \begin{pmatrix} \frac{1}{\lambda_1} & 0 \\ 0 & \frac{1}{\lambda_2} \end{pmatrix} U^T$$

et :

$$(x - \mu)^T \Gamma^{-1} (x - \mu) = \text{cte} \Leftrightarrow [U^T(x - \mu)]^T \begin{pmatrix} \frac{1}{\lambda_1} & 0 \\ 0 & \frac{1}{\lambda_2} \end{pmatrix} [U^T(x - \mu)]$$

Or  $U^T(x - \mu) = \begin{pmatrix} U_1^T(x - \mu) \\ U_2^T(x - \mu) \end{pmatrix}$  est le vecteur des coordonnées  $\begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$  dans le repère affine  $(\mu; U_1, U_2)$  du point  $x$




Dans ce nouveau repère, on a donc

$$\frac{c_1^2}{\lambda_1} + \frac{c_2^2}{\lambda_2} = c \quad (c > 0 \text{ const})$$

$\Rightarrow$  ellipsoïdes de demi-grand axe  $a = \sqrt{\lambda_1} \sqrt{c}$   
et demi-petit axe  $b = \sqrt{\lambda_2} \sqrt{c}$

si l'on convient de choisir au départ  $\lambda_1 > \lambda_2$

D'où la représentation :



## I.2. Vecteurs aléatoires réels

### Théorème Central Limite multidimensionnel

Soit  $X_1, X_2, \dots$  une suite de vecteurs aléatoires **indépendants et identiquement distribués** dans  $\mathbb{R}^d$  de vecteur moyenne  $\mu$  et de matrice de covariance  $\Gamma$  supposée **inversible**. Pour  $n \geq 1$ , on note encore  $S_n = X_1 + \dots + X_n \in \mathbb{R}^d$ .

Alors, pour tout hyper-rectangle  $[[a, b]]$  de  $\mathbb{R}^d$

$$P\left(\frac{S_n - n\mu}{\sqrt{n}} \in [[a, b]]\right) \rightarrow_n$$

$$\int_{[[a, b]]} f_X(x) dx$$

Attention aux notations :

$$x_j = \begin{pmatrix} x_1, j \\ \vdots \\ x_d, j \end{pmatrix} \in \mathbb{R}^d$$

où  $f$  est la densité de la loi gaussienne multivariée  $N(0, \Gamma)$ .

En pratique :

$$\frac{S_n}{n} \approx N\left(\mu, \frac{1}{n} \Gamma\right)$$

Exemple : voir TP n°1

## Explications TCL multidimensionnel :

$S_m = X_1 + \dots + X_m$  est un vecteur aléatoire

- de moyenne

$$E S_m = n \mu \quad \text{où } \mu = E X_1 = \dots = E X_n$$

- de covariance

$$\text{Cov}(S_m) = n \Gamma \quad \text{si } \Gamma = \text{Cov}(X_1) = \dots = \text{Cov}(X_n)$$

En effet :  $\text{Cov}(S_m) = E \left[ (X_1 - \mu + \dots + X_m - \mu)(X_1 - \mu + \dots + X_m - \mu)^T \right]$

$$= \sum_{i,j} E[(X_i - \mu)(X_j - \mu)^T]$$

$$= \sum_{i=1}^n E[(X_i - \mu)(X_i - \mu)^T] + \sum_{i \neq j} 0$$

$$= n \Gamma \quad \text{par indépendance}$$

Le TCL dit que  $S_m \approx N(n\mu, n\Gamma)$

on envoie que  $\frac{S_m}{m} \approx N(\mu, \frac{1}{m} \Gamma)$

# Illustrons avec l'exemple du TP1 (loi binomiale)

$$N = \begin{pmatrix} N_1 \\ N_2 \end{pmatrix} \text{ où } \begin{cases} N_1 = \mathbb{1}_{X_1=1} + \dots + \mathbb{1}_{X_m=1} \sim \mathcal{B}(n, p_1) \\ N_2 = \mathbb{1}_{X_1=2} + \dots + \mathbb{1}_{X_m=2} \sim \mathcal{B}(n, p_2) \end{cases}$$

$N = \varepsilon_1 + \dots + \varepsilon_n$  où  $\varepsilon_i = \begin{pmatrix} \mathbb{1}_{X_i=1} \\ \mathbb{1}_{X_i=2} \end{pmatrix}$  sont

des vecteurs i.i.d. de moyenne  $\mu = \begin{pmatrix} p_1 \\ p_2 \end{pmatrix}$

et de covariance  $\Gamma = \begin{pmatrix} p_1(1-p_1) & -p_1 p_2 \\ -p_1 p_2 & p_2(1-p_2) \end{pmatrix}$

Car  $\text{Cor}(\mathbb{1}_{X_i=1}, \mathbb{1}_{X_j=2}) = E[\mathbb{1}_{X_i=1} \mathbb{1}_{X_j=2}] - p_1 p_2$

Donc :  $\begin{pmatrix} N_1/n \\ N_2/n \end{pmatrix} \approx N\left(\begin{pmatrix} p_1 \\ p_2 \end{pmatrix}, \begin{pmatrix} p_1(1-p_1)/n & -\frac{p_1 p_2}{n} \\ -\frac{p_1 p_2}{n} & p_2(1-p_2)/n \end{pmatrix}\right)$

Commentaire général sur la loi  $N(\mu, \Gamma)$ :

Le TCL explique en grande partie toute l'importance de la loi  $N(\mu, \Gamma)$  en pratique.

Mais, son expression analytique est compliquée et ne permet pas de manipuler facilement des Vecteurs Gaussiens. Besoin d'une définition alternative plus facile à appréhender :

$$\text{idee } X \sim N(\mu, \sigma^2) \stackrel{d=1}{\iff} X = \mu + \sigma \varepsilon \text{ avec } \varepsilon \sim N(0, 1)$$

d'où  $X$  vecteur gaussien si  $X = \mu + A\varepsilon$  (transformation linéaire)  
avec  $\varepsilon \sim N(0, \text{Id})$

→ motion de bruit blanc gaussien

### I.3. Bruit blanc gaussien

---

**Définition.**  $X$  est dit *gaussien* (ou *normal*) *centré-réduit* si ses **composantes**  $X_1, \dots, X_d$  sont **indépendantes et de loi  $N(0, 1)$** . C'est un vecteur aléatoire *continu* admettant la *densité de probabilité*

$$\mathbf{x} = (x_1, \dots, x_d)^T \rightarrow \frac{1}{\sqrt{2\pi}^d} \exp\left(-\frac{\|\mathbf{x}\|^2}{2}\right)$$

où  $\|\mathbf{x}\| = \sqrt{x_1^2 + \dots + x_d^2}$  désigne la norme euclidienne usuelle de  $\mathbb{R}^d$ .

**Interprétation.** Les composantes du vecteur  $\mathbf{X}$  forment un bruit « blanc », ce qui renvoie aussi à la terminologie de **bruit blanc gaussien** (standard).


On a :  $\mathbf{X} \sim \mathbf{N}(\mathbf{0}, \mathbf{I}_d)$  où  $\mathbf{I}_d$  désigne la matrice *identité* de taille  $d$ , donc  $X$  est bien un vecteur gaussien au sens de la définition 1 (slide 11).

Dans toute la suite,  $\varepsilon$  désignera un vecteur aléatoire de loi  $\mathbf{N}(\mathbf{0}, \mathbf{I}_d)$ .

## I.3. Bruit blanc gaussien


---

Cas de la dimension  $d = 2$  :



### I.3. Bruit blanc gaussien

Simulation de  $n = 1000$  points selon la loi  $N(0, I_2)$



$(d = 2)$

environ 5 % des 1000  
points sont en dehors

$$\varepsilon \sim N(0, I_d) \Rightarrow U\varepsilon \sim N(0, I_d) \text{ dès que } U^T U = I_d$$

**U matrice orthogonale  $\Leftrightarrow$  U isométrie  $\Leftrightarrow$  U associée à une base orthonormée**

Propriété fondamentale pour un V.G. standard :


$$\varepsilon \sim N(0, I_d) \Rightarrow U\varepsilon \sim N(0, I_d) \text{ dès que } U^T U = I_d$$

Rappelons que  $U$  matrice orthogonale correspond à une isométrie puisque  $\|Ux\|^2 = \langle Ux | Ux \rangle = \langle U^T U x | x \rangle = \|x\|^2$ .  
Dans le cas  $d=2$ ,  $U$  est la matrice d'une rotation (isométrie directe) ou une symétrie par rapport à une droite (isométrie indirecte).

Ainsi la densité  $x \rightarrow \frac{1}{\sqrt{2\pi}^d} e^{-\frac{\|x\|^2}{2}}$  d'un V.G. standard

est invariante pour toute isométrie (le groupe des isométries).

La propriété en résulte, ce que l'on peut illustrer facilement dans le cas  $d=2$ :



courbes d'isoprobabilité des

V.a.  $\varepsilon \sim N(0, I_2)$   
de densité  $f(x) = \frac{1}{2\pi} e^{-\frac{1}{2}(x_1^2 + x_2^2)}$

U rotation d'angle  $\theta$   
(par exemple)

D domaine quelconque

Alors  $P(U \in D) = P(\varepsilon \in U^{-1}(D))$

OR  $P(\varepsilon \in U^{-1}(D)) = P(\varepsilon \in D)$

car c'est le même volume sous la cloche de Gauss (invariante par rotation) qui s'appuie sur D ou  $U^{-1}(D)$   
(se représenter le volume en question).

$$\text{Donc } P(U\varepsilon \in D) = P(\varepsilon \in D)$$

ce qui signifie que  $U\varepsilon$  a même loi que  $\varepsilon$  !

Formellement, on peut écrire dans le cas général :

$$\begin{aligned} P(U\varepsilon \in D) &= P(\varepsilon \in U^{-1}(D)) \\ &= \int_{U^{-1}(D)} e^{-\frac{1}{2} \|x\|^2} dx \end{aligned}$$

$$\text{Changement de variables: } x = U^{-1}y = U^T y$$

$$\text{Alors } dx_1 \dots dx_d = |\det(U^{-1})| dy_1 \dots dy_d$$

$$\text{soit } dx = dy \quad \text{car } |\det(U^{-1})| = 1 \quad (\text{cf. } U^{-1} \text{ isométrie}).$$

$$\begin{aligned} \text{De là, } P(U\varepsilon \in D) &= \int_{U^{-1}(D)} e^{-\frac{1}{2} \|U^{-1}y\|^2} dy \\ &= \int_D f(y) dy = P(\varepsilon \in D) // \end{aligned}$$

Retenir donc que  $U\varepsilon \sim N(0, Id)$  si  $\varepsilon \sim N(0, Id)$   
et  $U$  isométrie ( $U^T U = Id$ )

En particulier, si l'on choisit une base orthonormée quelconque de  $\mathbb{R}^d$  de la forme  $(\underbrace{U_1, U_2, \dots, U_d}_{\text{vecteurs colonnes de } \mathbb{R}^d})$

alors  $\varepsilon = \sum_{j=1}^d \langle \varepsilon | U_j \rangle U_j$  où donc

coordonnées dans  $\rightarrow$  la nouvelle base  $\begin{pmatrix} \langle \varepsilon | U_1 \rangle \\ \vdots \\ \langle \varepsilon | U_d \rangle \end{pmatrix} = \begin{pmatrix} U_1^T \varepsilon \\ \vdots \\ U_d^T \varepsilon \end{pmatrix} = U^T \varepsilon \sim N(0, Id)$

↑  
isométrie réciproque de  
 $U = (U_1 \dots U_d)^{d \times d}$

Donc, si  $E$  est un VG standard ( $\sim N(0, \text{Id})$ ), alors ses coordonnées dans n'importe quelle base orthonormée de  $\mathbb{R}^d$  forment encore un bruit blanc gaussien (des r.a. i.i.d.  $N(0, 1)$ )

On en déduit facilement les 2 conséquences qui suivent :

### I.3. Bruit blanc gaussien

---

**Conséquence 1** - La loi normale est stable pour l'addition :  $\forall n \geq 1$ , on a :

$X_1, \dots, X_n$  v.a.r. gaussiennes **indépendantes**  $\Rightarrow X_1 + \dots + X_n$  v.a.r. gaussienne

**Conséquence 2 (THÉORÈME DE COCHRAN\*)**

Soit  $P$  un projecteur orthogonal, i.e.  $P^2 = P$  et  $P^T = P$ . Alors :

- $P\boldsymbol{\varepsilon}$  et  $(I - P)\boldsymbol{\varepsilon}$  sont **indépendants, gaussiens centrés-réduits de degrés de liberté (ou de dimensions respectives)  $p$  et  $d - p$  où  $p = \dim(\text{Im } P)$ .**
- Les v.a.  $\|P\boldsymbol{\varepsilon}\|^2$  et  $\|(I - P)\boldsymbol{\varepsilon}\|^2$  sont **indépendantes** de lois respectives

$$\|P\boldsymbol{\varepsilon}\|^2 \sim \chi_p^2 \text{ et } \|(I - P)\boldsymbol{\varepsilon}\|^2 \sim \chi_{d-p}^2$$

(\*William Gemmel Cochran, 1909-1980)


Consequence 1 : il suffit de traiter le cas  $n = 2$  (puis récurrence sur  $n$ )

Soient donc  $X_1 \sim N(\mu_1, \sigma_1^2)$ ,  $X_2 \sim N(\mu_2, \sigma_2^2)$  independantes

Écrivons que :  $X_1 = \mu_1 + \sigma_1 \varepsilon_1$ ,  $X_2 = \mu_2 + \sigma_2 \varepsilon_2$  avec donc  $\varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \end{pmatrix} \sim N(0, I_2)$

Alors :  $X_1 + X_2 = \mu_1 + \mu_2 + \sqrt{\sigma_1^2 + \sigma_2^2} \tilde{\varepsilon}_1$

où  $\tilde{\varepsilon}_1 = \frac{\sigma_1}{\sqrt{\sigma_1^2 + \sigma_2^2}} \varepsilon_1 + \frac{\sigma_2}{\sqrt{\sigma_1^2 + \sigma_2^2}} \varepsilon_2$



Or  $U_1 = \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix}$  et  $U_2 = \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix}$  nouvelle base orthonormée

donc (en particulier),  $\tilde{\varepsilon}_1 = \langle \varepsilon | U_1 \rangle \sim N(0, 1)$

Comparaison avec le calcul direct dans le cas simple

$X_1 \sim N(0,1)$  et  $X_2 \sim N(0,1)$  indépendantes :

$X_1 + X_2$  est de la loi de densité (produit de convolution)

$$x \rightarrow f(x) = \int_{-\infty}^{+\infty} f_{X_1}(x_1) f_{X_2}(x-x_1) dx_1$$

$$\left( = \int_{-\infty}^{+\infty} f_{X_1}(x-x_2) f_{X_2}(x_2) dx_2 \text{ par symétrie} \right)$$

$$\text{Donc, } f(x) = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-x_1^2/2} \times \frac{1}{\sqrt{2\pi}} e^{-(x-x_1)^2/2} dx_1$$

$$\text{Or : } x_1^2 + (x-x_1)^2 = 2x_1^2 - 2xx_1 + x^2 = 2\left(x_1 - \frac{x}{2}\right)^2 + \frac{x^2}{2} - \frac{x^2}{4}$$

$$\text{D'où : } f(x) = \left( \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\left(x_1 - \frac{x}{2}\right)^2} dx_1 \right) \times \frac{e^{-\frac{x^2}{4}}}{\sqrt{2\pi}}$$

Par un petit changement de variable ( $x_1 \leftarrow x_1 - \frac{x}{2}$ ) :

$$f(x) = \left( \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-x_1^2} dx_1 \right) \times \frac{e^{-\frac{1}{2} \frac{x^2}{2}}}{\sqrt{2\pi}}$$
$$= \frac{1}{\sqrt{2}} \quad (\text{poser } x_1 = \frac{\tilde{x}_1}{\sqrt{2}})$$

donc  $f(x) = \frac{1}{\sqrt{2}\sqrt{2\pi}} e^{-\frac{1}{2} \frac{x^2}{2}}$

C'est bien la loi  $N(0, 1+1) = N(0, 2)$

On mesure son ut. exemple l'intérêt à raisonner de manière géométrique ...

## Conséquence 2 (preuve)


Rappel  $P : \mathbb{R}^d \rightarrow \mathbb{R}^d$  linéaire ( $P$  identifié à sa matrice dans la base canonique :  $P(x) = Px$ ) est un projecteur

Si  $P^2 = P$  ( $P \circ P = P$ )

Alors  $\mathbb{R}^d = \text{Im } P \oplus \text{Ker } P$  puisque

$$x = \underbrace{Px}_{\in \text{Im } P} + \underbrace{x - Px}_{\in \text{Ker } P} \quad (\text{décomposition unique})$$

et (géométriquement)  $P$  correspond à la projection sur le sous-espace vectoriel  $\text{Im } P$  parallèlement à  $\text{Ker } P$ .



$P$  est un projecteur orthogonal si, de plus,  $\text{Im } P \perp \ker P$

Cela équivaut à  $P = P^T$  ( $P$  symétrique)

En effet, si  $P = P^T$ , alors

$$\langle Pu | v \rangle = u^T P^T v = u^T Pv = \langle u | Pv \rangle$$

et, si  $v \in \ker P$ , on a bien  $\langle Pu | v \rangle = 0$  pour tout  $u$ ,

soit  $\ker P \perp \text{Im } P$

Dans l'autre sens, si  $\ker P \perp \text{Im } P$ , alors

$$\langle Pu | v \rangle = \underbrace{\langle Pu | Pv + v - Pv \rangle}_{\in \text{Im } P} = \underbrace{\langle Pu | Pv \rangle}_0 \quad \text{expression symétrique}$$

donc  $\langle Pu | v \rangle = \langle Pv | u \rangle = \langle u | Pv \rangle$  en  $u$  et  $v$   
et  $P = P^T$  ( $u^T P^T v = u^T Pv, \forall u, v$ )

Avec ces rappels le théorème de Cochran devient clair.

En effet, prenons  $(U_1, \dots, U_p)$  une base orthonormée de  $\text{Im } P$   
 $(U_{p+1}, \dots, U_d)$  une base de  $\text{ker } P$  (de dim  $d-p$ ).

Alors  $(U_1, \dots, U_p, U_{p+1}, \dots, U_d)$  base orthonormée de  $\mathbb{R}^d$ .

Puis,  $\varepsilon = \underbrace{\sum_{i=1}^p \langle \varepsilon | U_i \rangle U_i}_{= P\varepsilon} + \underbrace{\sum_{i=p+1}^d \langle \varepsilon | U_i \rangle U_i}_{= \varepsilon - P\varepsilon}$

Comme les coordonnées  $(\langle \varepsilon | U_i \rangle)_i$  sont i.i.d.  $N(0, 1)$ ,  
les vecteurs  $P\varepsilon$  et  $\varepsilon - P\varepsilon$  sont bien des V. gaussiens  
standard dans  $\text{Im } P \cong \mathbb{R}^p$  et  $\text{ker } P \cong \mathbb{R}^{d-p}$   
respectivement.

De plus,  $P\varepsilon$  et  $(I-P)\varepsilon$  sont indépendants et

$$\|P\varepsilon\|^2 = \sum_{i=1}^p \langle \varepsilon | u_i \rangle^2 \sim \chi^2(p)$$

$$\|(I-P)\varepsilon\|^2 = \sum_{i=p+1}^d \langle \varepsilon | u_i \rangle^2 \sim \chi^2(d-p)$$

par définition de la loi du  $\chi^2$  à  $d$  degrés de liberté :

$$\chi^2(d) = \text{loi de } z_1^2 + \dots + z_d^2 = \|Z\|^2 \text{ où } Z \sim N(0, I_d)$$

Remarquer enfin que  $P\varepsilon$  est bien un vecteur à  $p$  degrés de liberté (il est dans  $\text{Im } P$ ), donc dégénéré si  $p < d$ .

$$\text{De plus: } \text{Cov}(P\varepsilon) = P I_d P^T = P^2 = P \quad //$$

(qui est bien non inversible si  $p < d$ )

On donnera au final une définition d'un V.G. qui englobe le cas du théorème de Cochran où :

$$\left\{ \begin{array}{ll} P\varepsilon & V.G. \in \text{sous-espace de } \mathbb{R}^d \\ (I - P)\varepsilon & V.G. \in \text{sous-espace de } \mathbb{R}^{d-d} \end{array} \right.$$

de dim p

Mais, on regarde d'abord le cas non diagonalisé !

## I.4. Vecteurs gaussiens quelconques

---

**Définition d'un vecteur gaussien (seconde approche).**

Un vecteur aléatoire  $X = (X_1, \dots, X_d)^T \in \mathbb{R}^d$  est dit *gaussien (ou multi-gaussien)* de **dimension réelle  $d$**  s'il existe  $\mu = (\mu_1, \dots, \mu_d) \in \mathbb{R}^d$ , une matrice  $A$  de taille  $d \times d$  **inversible** et  $\varepsilon \sim N(0, I_d)$  tels que

$$X = \mu + A\varepsilon$$

Dit autrement,  $X$  est l'image par une **transformation affine** d'un bruit blanc gaussien centré-réduit.

**Moyenne et matrice de covariance :**

$$E(X) = \mu$$

$$\text{Cov}(X) = AA^T$$

## I.4. Vecteurs gaussiens quelconques

---

**Définition d'un vecteur gaussien (seconde approche).**

Un vecteur aléatoire  $X = (X_1, \dots, X_d)^T \in \mathbb{R}^d$  est dit *gaussien (ou multi-gaussien)* de **dimension réelle  $d$**  s'il existe  $\mu = (\mu_1, \dots, \mu_d) \in \mathbb{R}^d$ , une matrice  $A$  de taille  $d \times d$  **inversible** et  $\varepsilon \sim N(0, I_d)$  tels que

$$X = \mu + A\varepsilon$$

Dit autrement,  $X$  est l'image par une **transformation affine** d'un bruit blanc gaussien centré-réduit.

**Moyenne et matrice de covariance :**

$$E(X) = \mu$$

$$\text{Cov}(X) = AA^T$$

## I.4. Vecteurs gaussiens quelconques

### Densité et décomposition de Mahalanobis\*.

Soit  $X$  un vecteur de la forme  $X = \mu + A\epsilon \in \mathbb{R}^d$  avec  $A$  inversible et  $\epsilon \sim N(0, I_d)$ . On a  $\Gamma = \text{Cov}(X) = AA^T$  inversible et  $X$  admet la densité

$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)}} \frac{1}{\sqrt{2\pi}^d} \exp\left(-\frac{1}{2} \langle x - \mu, \Gamma^{-1}(x - \mu) \rangle\right)$$

En bref,  **$X \sim N(\mu, \Gamma)$  et  $X$  gaussien au sens de la première définition.**

On a encore la décomposition  $X = \mu + U\Sigma\epsilon$  avec  $\epsilon \sim N(0, I_d)$  et où les matrices  $\Sigma$  et  $U$  sont obtenues par diagonalisation en base orthonormée de la matrice de covariance :  $\Gamma = U\Sigma^2U^T$  avec  $U^TU = I_d$ .

(\* Prasanta Chandra Mahalanobis, 1893-1972)

## I.4. Vecteurs gaussiens quelconques

---

**COROLLAIRE.** ☺

Si  $X \in \mathbb{R}^d$  est un vecteur gaussien de dimension réelle  $d$ , alors

$$\begin{aligned} X_1, \dots, X_d \text{ indépendantes} &\Leftrightarrow \text{Cov}(X_i, X_j) = 0 \text{ pour } i \neq j \\ &\Leftrightarrow \Gamma \text{ matrice diagonale} \end{aligned}$$

**SIMULATION DE  $\mathbf{X} \sim N(\mu, \Gamma)$ .**

- Faire la décomposition de Cholesky de  $\Gamma$ :  $\Gamma = SS^T$  avec  $S$  triangulaire inférieure (et diagonale positive)
- Simuler  $\varepsilon \sim N(0, I_d)$
- Calculer  $X = \mu + S\varepsilon$

## Définition d'un vecteur gaussien (cas général).

Un vecteur aléatoire  $X = (X_1, \dots, X_p)^T \in \mathbb{R}^p$  est dit *gaussien (ou multi-gaussien)* s'il existe  $\mu = (\mu_1, \dots, \mu_p) \in \mathbb{R}^p$ , une matrice  $A$  de taille  $p \times q$  et  $\varepsilon \sim N(0, I_q)$  tels que

$$X = \mu + A\varepsilon$$

$X$  image par une **transformation affine** de  $\mathbb{R}^q$  dans  $\mathbb{R}^p$  d'un bruit blanc gaussien centré-réduit de dimension  $q$ .

## Moyenne et matrice de covariance du vecteur $X$ :

$$E(X) = \mu \in \mathbb{R}^p$$

$$\Gamma = \text{Cov}(X) = AA^T \text{ de taille } p \times p$$

Deux cas sont à envisager :

- $\Gamma = \text{Cov}(X) = AA^T$  est **inversible**, alors  $X$  est de dimension réelle  $d = p$  et admet la densité

$$x \rightarrow \frac{1}{\sqrt{\det(\Gamma)}} \frac{1}{\sqrt{2\pi}^p} \exp\left(-\frac{1}{2} \langle x - \mu, \Gamma^{-1}(x - \mu) \rangle\right)$$

- $\Gamma$  est **non inversible**,  $X$  est dit « dégénéré » et « vit » en réalité dans un sous-espace affine de dimension  $d < p$  (et  $d \leq q$ ). De manière plus précise, on a

$$X = \mu + \sqrt{\lambda_1} \varepsilon_1 U_1 + \dots + \sqrt{\lambda_d} \varepsilon_d U_d ; \varepsilon \sim N(0, I_d)$$

en écrivant que  $\Gamma = U \Lambda U^T$  avec  $U^T U = I_p$  et  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d > 0$  les valeurs propres non nulles de  $\Gamma$ .

**Dans les deux cas, on dira que  $X$  est de loi  $N(\mu, \Gamma)$ .**

**Exemple (cf. TP1) :** soit  $X$  une variable aléatoire à 3 modalités 0, 1 ou 2.

Notons  $Z_0 = \frac{1}{\sqrt{p_0}} (1_{X=0} - p_0)$ ,  $Z_1 = \frac{1}{\sqrt{p_1}} (1_{X=1} - p_1)$ ,  $Z_2 = \frac{1}{\sqrt{p_2}} (1_{X=2} - p_2)$

puis  $Z$  le vecteur dans  $\mathbb{R}^3$  de composantes  $Z_0$ ,  $Z_1$  et  $Z_2$ .


Par construction,  $\mu = E(Z) = 0$ .

Alors,  $\Gamma = \text{Cov}(Z)$  est une matrice **non inversible** et le théorème central limite affirme que



$$\frac{1}{\sqrt{n}} (Z^{(1)} + \dots + Z^{(n)}) \xrightarrow{n} N(\mathbf{0}, \Gamma)$$

si les  $Z^{(k)}$  ( $k \geq 1$ ) sont des vecteurs aléatoires indépendants de même loi que  $Z \in \mathbb{R}^3$ .

**Exercice :** analyser la loi en question et en déduire le test classique d'adéquation à une loi discrète ayant 3 modalités. Cas général.



**Une simulation d'un bruit blanc gaussien de taille 100 visualisé par un tracé séquentiel de ses composantes**



## Décomposition en valeurs singulières (DVS ou SVD):

A étant donnée de taille  $p \times q$ , il existe une matrice  $p \times q$   $\Sigma$  diagonale à termes diagonaux  $\geq 0$  telle que

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T \quad \text{avec} \quad \mathbf{V}^T\mathbf{V} = \mathbf{I}_q \text{ et } \mathbf{U}^T\mathbf{U} = \mathbf{I}_p$$

Ainsi,  $\Gamma = \mathbf{A}\mathbf{A}^T = \mathbf{U}\Lambda_p\mathbf{U}^T$       avec  $\Lambda_p = \Sigma\Sigma^T$  diagonale  $p \times p$

$$\mathbf{A}^T\mathbf{A} = \mathbf{V}\Lambda_q\mathbf{V}^T \quad \text{avec } \Lambda_q = \Sigma^T\Sigma \text{ diagonale } q \times q$$

Les termes diagonaux de  $\Sigma$  sont appelés *valeurs singulières* de la matrice A et sont le plus souvent rangées par ordre décroissant.

## II.1. Lois conditionnelles dans le cas discret

---

Soient  $Y$  v.a.r. et  $X$  v.a. **discrète**  $X \in \{x_1, x_2, \dots, x_p\}$ .

On appelle *loi conditionnelle de Y sachant X = x<sub>k</sub>* la loi de probabilité notée  $\mu_{Y|X=x_k}$  définie par

$$\mu_{Y|X=x_k}([a, b]) = P(Y \in [a, b] | X = x_k) = \frac{P(Y \in [a, b] \text{ et } X = x_k)}{P(X = x_k)}$$

L'ensemble des  $p$  lois de probabilité  $\mu_{Y|X=x_k}$  ( $1 \leq k \leq p$ ) est appelé *système des lois conditionnelles de Y sachant X*.

**Exemple 1.** Loi du pile ou face deux fois :  $Y$  = nombre total de pile,  $X$  résultat du premier lancer

## II.1. Lois conditionnelles dans le cas discret

**Cas où Y est également discrète :  $Y \in \{y_1, y_2, \dots, y_q\}$**

**les p lois conditionnelles de Y sachant X s'écrivent**

$$\mu_{Y|X=x_i} = \sum_{j=1}^q p_{j|i} \delta_{y_j} \text{ où } p_{j|i} = \frac{p_{ij}}{p_{i.}} = \frac{P(Y = y_j \text{ et } X = x_i)}{P(X = x_i)}$$

On a (!)

**X, Y indépendantes  $\Leftrightarrow \mu_{Y|X=x_i} = \mu_Y$  pour tout i**

$$\Leftrightarrow p_{j|i} = \frac{P(Y = y_j \text{ et } X = x_i)}{P(X = x_i)} = P(Y = y_j) = p_{.j}$$

## II.2. Lois conditionnelles dans le cas continu

$(X, Y) \in \mathbb{R}^2$  est un vecteur continu de densité  $(x, y) \rightarrow f_{(X, Y)}(x, y)$

La loi conditionnelle de  $Y$  sachant  $X = x$  est définie par la *densité conditionnelle* suivante

$$f_{Y|X=x}(y) = \frac{f_{(X, Y)}(x, y)}{f_X(x)}$$

pour tout  $x$  tel que  $f_X(x) = \int_{-\infty}^{+\infty} f_{(X, Y)}(x, y) dy \neq 0.$

**Exemple 2.**  $Y = X + \varepsilon$  où  $X \sim N(\mu_X, \sigma_X^2)$  et  $\varepsilon \sim N(0, \sigma^2)$  sont indépendantes

## II.2. Lois conditionnelles dans le cas continu

On a (!)

$$X, Y \text{ indépendantes} \Leftrightarrow \mu_{Y|X=x} = \mu_Y \Leftrightarrow f_{Y|X=x}(y) = \frac{f_{(X,Y)}(x,y)}{f_X(x)} = f_Y(y)$$

**FORMULE DE BAYES.**

$$f_{X|Y=y}(x) = \frac{f_{Y|X=x}(y) \times f_X(x)}{f_Y(y)}$$

sachant que  $f_Y(y) = \int_{-\infty}^{+\infty} f_{Y|X=x}(y) \times f_X(x) dx$  est simplement une constante de normalisation.

## II.3. Espérance conditionnelle

---

On a vu que l'information apportée par  $X = (X_1, \dots, X_p)$  modifie les probabilités que l'on a sur  $Y$  avec la notion de loi conditionnelle.

Il est tout autant naturel de se demander en quoi la connaissance des variables  $X_1, \dots, X_p$  réduit ou non l'incertitude que l'on a sur  $Y$  si l'on mesure cette incertitude en terme de dispersion usuelle, i.e. de variance.

😊😊😊 On introduit pour cela l'espace vectoriel  $L^2(P)$  des v.a. admettant une variance et muni du produit scalaire suivant :


$$\langle U, V \rangle = E(UV)$$

## II.3. Espérance conditionnelle

Définition de l'*espérance conditionnelle*  $E(Y | X)$  :

$E(Y | X)$  est la projection orthogonale de  $Y$  sur le sous-espace  $L^2(X)$  de  $L^2(P)$  défini par

$$L^2(X) = \{ Z = \varphi(X) \in L^2(P) \text{ avec } \varphi : I\!\!R^p \rightarrow I\!\!R \}.$$



Bien noter que  $E(Y | X)$  est une variable aléatoire!

## II.3. Espérance conditionnelle

### Formules de l'espérance totale et de la variance totale

$$Y = E(Y | X) + \varepsilon \quad \text{avec } E(\varepsilon) = 0 \text{ et :}$$

$$\text{Cov}(\varepsilon, \varphi(X)) = \langle \varepsilon, \varphi(X) \rangle = 0 \text{ si } \varphi(X) \in L^2(X)$$

En particulier :  $E(E(Y | X)) = E(Y)$  et  $\text{Var}(Y) = \text{Var}(E(Y | X)) + \text{Var}(\varepsilon)$

Dans cette décomposition,  $\varepsilon$  est de **variance minimale** : on ne peut pas réduire plus la variance résiduelle!

**Définition.** On définit le pourcentage de la variance de  $Y$  expliquée par  $X$  selon

$$\% \text{ de variance expliquée} = 100 \times \frac{\text{Var}(E(Y | X))}{\text{Var}(Y)} \%$$

$$\% \text{ de variance non expliquée ou résiduelle} = 100 \times \frac{\text{Var}(\varepsilon)}{\text{Var}(Y)} \%$$

## II.3. Espérance conditionnelle

**Espérance conditionnelle comme moyenne de la loi conditionnelle.** On a simplement

$$E(Y | X) = m(X)$$

où la fonction  $m$  vérifie

$$m(x) = \int_{-\infty}^{+\infty} y \times f_{Y|X=x}(y) dy = E(Y | X = x)$$

i.e.  $m(x)$  est la moyenne de la loi conditionnelle de  $Y$  sachant  $X = x$ .

De plus, on a la **formule de transfert conditionnel**

$$E(f(Y) | X) = \varphi(X) \text{ où } \varphi \text{ se calcule selon } \varphi(x) = \int f(y) d\mu_{Y|X=x}(y)$$

## II.3. Espérance conditionnelle

---

On termine par le cas gaussien.

**Si  $(X, Y) = (X_1, \dots, X_p, Y)$  est un vecteur gaussien, alors :**

- $E(Y | X) = E_L(Y | X)$  est une **fonction linéaire (affine)** des  $X_k$
- Le résidu  $\varepsilon$  est **indépendant** des  $X_k$  et de loi  $N(0, \text{Var}(\varepsilon))$  où

$$\text{Var}(\varepsilon) = \text{Var}(Y) - \text{Var}(E(Y | X))$$

- **La loi conditionnelle de  $Y$  sachant  $X = x$  est gaussienne de variance indépendante de  $x$  et égale à la variance du résidu  $\varepsilon$**