Majeure Science des données 2020-21

UP3: 'Analyse de données et données temporelles'

Cours 'Analyse de données multivariées -Analyses factorielles'

TP n°2 - Analyse factorielle des correspondances - octobre 2020 TP 1H30

Cette séance de 1h30 de TP est consacrée à l'Analyse factorielle des correspondances en priorité et à finaliser le TP ACP et la robustesse par *bootstrap* (questions notamment).

Pour cette AFC les objectifs sont :

- D'assimiler les bases de la transformation utilisée en AFC
- De savoir programmer les différentes étapes de l'AFC sur deux variables X et Y ayant n modalités pour X et p modalités pour Y
- D'étudier la représentativité de l'AFC mise en œuvre sur un jeu de données : avec pour la réduction de dimension 1) le choix de la dimension et 2) d'évaluer la qualité de la projection des points lignes et points colonnes.
- d'interpréter les données issues de l'AFC.

La mise en œuvre se fera sur les données de modèles de d'enquêtes réalisées sur un sondage sur la perception du travail réalisé et qualité de vie exprimée (TP_AFCmajeur1718travail.xls). Télécharger le fichier sur : https://campus.emse.fr/

A noter :

Il s'agira pour vous de vous constituer un programme qui fonctionne, et efficace pour pouvoir être utilisé soit dans les TP suivants, soit sur *l'étude de cas* qui sera à rendre et notée à la fin de cette UP.

Il s'agit de:

- 1. Mettre au point un script qui permet successivement de :
- faire les transformations de données à partir des données fournies et des matrices nécessaires à la réduction
- faire la réduction et la projection du nuage des points lignes dans l'espace \mathbb{R}^p afin d'identifier les hyperplans pour lesquels l'inertie projetée est maximale : les hyperplans sont associés aux p directions de l'espace, chaque axe factoriel est de vecteur propre u (respectivement matrice U) et une valeur propre λ (respectivement matrice Λ).
- le tracé des points dans l'espace réduit choisi

Vous pouvez envisager aussi en parallèle le cas de l'AFC sur l'espace de Rⁿ.

```
Vous pouvez tester: summary(don) et le test du Chi2 (que fait-il?) avec res.test.chi2<- chisq.test(don) round(res.test.chi2$expected,1) round(res.test.chi2$residuals^2, 2) round(100 * res.test.chi2$residuals^2 / res.test.chi2$stat, 2)
```

- 2. Pour ce qui est de la qualité de l'AFC et de la qualité de projections des points, la similitude entre ACP et AFC vous permet de réutiliser les développements fait dans le TP précèdent
- 3. Comparer avec la CA (usage : res.ca <- CA(don[,1:3])) de FactoMineR dont l'output est :

 Eig :a matrix containing all the eigenvalues, the percentage of variance and the cumulative percentage of variance

 Col :a list of matrices with all the results for the column variable (coordinates, square cosine, contributions, inertia)

 Row: a list of matrices with all the results for the row variable (coordinates, square cosine, contributions, inertia)

 col.sup :a list of matrices containing all the results for the supplementary column points (coordinates, square cosine)

 row.sup :a list of matrices containing all the results for the supplementary row points (coordinates, square cosine)

 quanti.sup :if quanti.sup is not NULL, a matrix containing the results for the supplementary continuous variables (coordinates, square cosine)

 quali.sup : if quali.sup is not NULL, a list of matrices with all the results for the supplementary categorical variables (coordinates of each categories of each variables, v.test which is a criterion with a Normal distribution, square correlation ratio)

 :a list with some statistics
- 4. La mise en œuvre se fera sur les données d'enquête réalisée sur lors d'un sondage dans une entreprise sur la perception du travail réalisé ⁽¹⁾ : fichier TP_AFCmajeur1718travail.xls :

Cette enquête avait pour cadre la pénibilité du travail dans une entreprise : vous disposez de deux questions à choisir pour la mise en œuvre de l'AFC:

- 1) en fonction du type de Fonction exercée et du sexe de l'individu, qui concerne l'adéquation entre temps de travail et travail à réaliser

- 2) en fonction du type de Fonction exercée et du sexe de l'individu, qui concerne la qualité de vie au travail exprimée.
- 5. Vous pouvez traiter par AFC ce type de données par exemple: tester une AFC entre identité (H /F) et qualité de vie, entre fonction et qualité de vie, entre identité et adéquation entre temps de travail...Peut-on traiter simultanément plusieurs modalités ?

Modalité par *Fonction*: Administratif: modalité 1 Technicien (OS): modalité 2 ingénieur: 3 technicien supérieur: 4 direction: modalité 5 contractuel_S1: modalité 6 contractuel_S2: modalité 7 non_repondu: 0 Modalité par *Sexe*: F: 2 H: 1 non_repondu: 0

A la question 'temps nécessaire pour effectuer mon travail' : les modalités sont

- modalité 8 : je suis en sous charge de travail
- modalité 2 : la charge de travail correspond à mes horaires de travail
- modalité 4 : je ne dépasse pas mes horaires de travail
- modalité 16 : je suis surchargé et je dépasse mes horaires de travail
- non_repondu: 99

A la question : la qualité de vie au travail a été évaluée selon 3 modalités

- modalité 2 : améliorer
- modalité 4 : maintenue
- modalité 16 : dégradée